

L'intelligence documentaire en action

De l'extraction multimodale au raisonnement sur les KPI financiers, mon parcours d'AI Engineer chez Amadeus



Walid Benmaarouf

Type de stage: Alternance

Entreprise: Amadeus

Tuteur entreprise: Abdessamad Bakhada

Tuteur Télécom Saint-Étienne: Olivier Alata

Dates de stage: 31/08/2025 - 12/09/2026



Table des matières

Remerciements	4
Glossaire des termes techniques	5
1 Contexte du travail	6
1.1 Présentation de l'entreprise	6
1.2 Engagement RSDD	6
1.2.1 Questionnement : développement durable et systèmes numériques	6
1.3 Positionnement dans la structure	7
1.4 Contexte, position et problématique	8
1.5 Objectifs de l'alternance	8
2 Analyse du travail réalisé	8
2.1 Présentation générale des missions	8
2.2 Planning général	9
2.3 Spécifications du système	10
2.4 Conception du système d'intelligence documentaire	12
2.4.1 Ingestion et compréhension multimodales	12
2.4.2 Partitionnement initial par compagnie et période	13
2.5 Retrieval hybride	15
2.5.1 Représentation symbolique par vecteur signé	15
2.5.2 Catégorisation et classement des fragments	17
2.6 Extraction structurée et reconstruction des KPI	18
2.6.1 Graphe de dépendances et construction du contexte de résolution	19
2.6.2 Agent de résolution et orchestration itérative des outils	19
2.7 Validation et mécanismes de correction	21
2.8 Industrialisation et observabilité	21
2.9 Résultats et perspectives	22
2.10 Difficultés, limites et regard critique	24
3 Entretien métier	24
4 Bilan personnel	26



5	Projet professionnel	28
	Conclusion générale	29
6	Bibliographie	30
A	Annexes	31
A	Visualisation des impacts– Diagrammes Butterfly	31
B	Pipeline d’ingestion et de préparation des données	32
C	Système de retrieval hybride symbolique-sémantique	34
D	Génération structurée et reconstruction des KPI	36
E	Exemples d’exécution et métriques techniques	37
E.1	Exemple d’exécution du retrieval et du solver	38
E.2	Suivi du coût et de la consommation des modèles	38

Remerciements

Cette année d'alternance a représenté une étape particulièrement importante de mon parcours. Elle m'a permis de confronter mes connaissances académiques à des problématiques industrielles concrètes, de gagner en autonomie et surtout de faire évoluer ma manière d'aborder un problème d'ingénierie.

Je souhaite tout d'abord remercier l'ensemble des équipes d'Amadeus qui m'ont accueilli et accompagné tout au long de cette expérience. J'ai eu la chance d'évoluer dans un environnement à la fois exigeant, bienveillant et très agréable au quotidien. La disponibilité des membres de l'équipe, leur simplicité dans les échanges et leur volonté de partager leurs connaissances ont largement facilité mon intégration et rendu cette année particulièrement enrichissante.

Je remercie également toutes les personnes avec lesquelles j'ai pu échanger autour du projet, notamment les équipes techniques, les Product Owners et les différentes parties prenantes. Ces discussions m'ont permis de mieux comprendre les enjeux métier, les contraintes de l'écosystème Amadeus et la manière dont une solution d'intelligence artificielle doit s'intégrer dans un environnement industriel plus large.

Je tiens à adresser un remerciement particulier à M. Abdessamad Bakhada, mon tuteur chez Amadeus, pour sa confiance, sa disponibilité et la qualité de son accompagnement. Nos échanges réguliers m'ont souvent poussé à dépasser une approche uniquement fondée sur les connaissances que je possédais déjà, à explorer de nouvelles pistes et à remettre en question mes premières solutions. Cette liberté d'exploration, combinée à ses conseils et à sa proximité au quotidien, a beaucoup contribué à ma progression pendant cette alternance.

Je souhaite également remercier Télécom Saint-Étienne et l'ensemble du corps enseignant pour les connaissances, la rigueur et les méthodes de travail transmises tout au long de ma formation. Je remercie tout particulièrement M. Olivier Alata, mon tuteur académique, pour son suivi, ses conseils et son accompagnement durant cette dernière année.

Je tiens enfin à remercier ma famille pour son soutien constant tout au long de mon parcours. Sa confiance, ses encouragements et sa présence m'ont accompagné pendant toutes ces années d'études et ont largement contribué à me permettre d'arriver jusqu'à cette dernière étape de ma formation.

Enfin, je remercie toutes les personnes qui ont contribué, directement ou indirectement, à cette expérience. Cette alternance restera pour moi une période marquante, autant pour les compétences que j'y ai développées que pour les rencontres, les échanges et la vision plus concrète du métier d'ingénieur qu'elle m'a permis d'acquérir.

Glossaire des termes techniques

Terme	Définition
LLM	Large Language Model. Modèle de langage de grande taille entraîné sur de grands corpus de données.
VLM	Vision-Language Model. Modèle capable de traiter conjointement des informations visuelles et textuelles.
RAG	Retrieval-Augmented Generation. Architecture combinant recherche d'information et génération par modèle de langage.
KPI	Key Performance Indicator. Indicateur permettant de quantifier une performance ou une information métier.
OCR	Optical Character Recognition. Technique permettant d'extraire du texte à partir d'une représentation visuelle.
Embedding	Représentation vectorielle dense d'un contenu textuel ou multimodal dans un espace latent.
Vector Database	Base de données optimisée pour le stockage et la recherche de représentations vectorielles.
Metadata	Informations décrivant le contenu ou le contexte d'un document, d'une page ou d'un fragment.
Dependency Graph	Graphe décrivant les dépendances entre KPI et variables nécessaires à leur reconstruction.
CI/CD	Continuous Integration / Continuous Deployment. Ensemble de pratiques permettant d'automatiser les tests, builds et déploiements.
Observability	Capacité à comprendre l'état interne d'un système à partir de logs, métriques et traces.
Amazon S3	Service de stockage objet utilisé pour conserver les documents, artefacts et résultats.
Prometheus	Système de collecte et stockage de métriques temporelles.
Grafana	Plateforme de visualisation et d'analyse de métriques.
Json	JavaScript Object Notation. Format structuré utilisé pour représenter et échanger des données.
CSV	Comma-Separated Values. Format tabulaire utilisé pour stocker ou échanger des données.
Chunk	Fragment de document utilisé comme unité d'indexation et de retrieval.
Token	Unité élémentaire utilisée par les modèles de langage pour représenter et traiter du texte.
Apache Spark	Moteur distribué de traitement de données à grande échelle.
PI Planning	Planning Interval Planning. Séance de planification à moyen terme utilisée dans les organisations agiles à grande échelle.

1. Contexte du travail

1.1 Présentation de l'entreprise

Amadeus est un groupe technologique international spécialisé dans les solutions informatiques destinées au secteur du voyage. Son siège est situé à Madrid et le groupe est implanté dans de nombreux pays. En France, le site de Sophia Antipolis constitue l'un de ses principaux centres technologiques.

L'entreprise développe des systèmes utilisés par différents acteurs du voyage : compagnies aériennes, aéroports, hôtels, agences de voyage et autres opérateurs du secteur. Ses activités mobilisent ainsi des profils variés : ingénieurs logiciels, Data Engineers, spécialistes cloud et infrastructure, experts en intelligence artificielle, Product Owners, équipes fonctionnelles et fonctions support.

En 2025, Amadeus comptait environ 20 600 collaborateurs et réalisait un chiffre d'affaires supérieur à 6,5 milliards d'euros. Cette dimension internationale implique des infrastructures informatiques importantes et une forte activité de recherche, de développement et d'exploitation de systèmes numériques.

1.2 Engagement RSDD

La politique environnementale du groupe est notamment pilotée par **Lucas Bobes**, *Group Environmental Officer and Head of ESG Reporting*. Il assure le suivi de la performance environnementale, le reporting ESG et l'amélioration de l'empreinte des opérations.

La démarche d'Amadeus s'appuie sur plusieurs référentiels et engagements reconnus, notamment le **Pacte mondial des Nations unies**, les standards **GRI** ainsi que des certifications telles que **EN 50600** et **ISO/IEC 22237** pour son principal Data Center. Certains sites disposent également de certifications environnementales comme **LEED Gold** ou **BREEAM**.

Au cours des dernières années, cette démarche s'est renforcée avec l'engagement auprès de la **SBTi** en 2022 et la validation d'objectifs climatiques visant notamment, d'ici 2030, une réduction de **42 %** des émissions de Scope 1 et 2 et de **25 %** du Scope 3 par rapport à 2022. À Sophia Antipolis, ces engagements se traduisent notamment par le projet **Helios**, basé sur la géothermie.

1.2.1 Questionnement : développement durable et systèmes numériques

Dans le cadre de mon alternance, la thématique du développement durable est particulièrement pertinente car le projet repose sur des traitements informatiques intensifs : stockage de documents, traitement d'images, génération d'embeddings et appels à des modèles d'intelligence artificielle. L'impact environnemental d'un tel service ne se limite donc pas au poste de travail de l'utilisateur, mais concerne l'ensemble de son cycle de vie : développement, entraînement ou utilisation des modèles, infrastructure cloud, stockage, calcul et exploitation.

Amadeus agit déjà à l'échelle de ses infrastructures en augmentant la part d'énergie renouvelable et en améliorant l'efficacité de ses systèmes informatiques. À l'échelle d'un projet d'IA, cette démarche peut être prolongée par des choix d'architecture visant à éviter les traitements inutiles. Dans le système développé, tous les documents et toutes les pages ne nécessitent pas le même niveau de traitement. L'utilisation de mécanismes de sélection, de retrieval et de validation permet de limiter les informations transmises aux modèles et d'éviter certains appels inutiles.

Cette approche présente un double intérêt. D'un point de vue économique, la diminution du nombre

d'appels et du volume de données traitées réduit le coût du service. D'un point de vue environnemental, elle limite également les ressources de calcul mobilisées. Le suivi de la latence, du nombre de tokens et des ressources utilisées permet ainsi d'intégrer la consommation du système parmi les critères d'observabilité.

Une limite demeure cependant : l'utilisation de modèles de grande taille repose sur des infrastructures externes dont l'empreinte exacte n'est pas toujours directement accessible au développeur. L'enjeu consiste donc moins à supprimer tout impact qu'à concevoir un système proportionné au besoin : utiliser les traitements les plus coûteux uniquement lorsqu'ils apportent une valeur réelle et privilégier des opérations déterministes plus simples lorsqu'elles sont suffisantes. Cette logique rejoint une démarche d'écoconception logicielle dans laquelle performance, coût et consommation de ressources sont considérés dès la conception du système.

1.3 Positionnement dans la structure

Mon alternance s'est déroulée au sein d'une équipe Data Engineering d'Amadeus, encadrée par Mireille Boyer. L'équipe regroupe différents profils, notamment des Data Engineers, Data Scientists, Software Developers et profils juniors. J'y occupais un poste d'apprenti spécialisé en intelligence artificielle générative.

La Figure 1 présente mon positionnement au sein de l'équipe.




FIGURE 1 – Positionnement au sein de l'équipe Data Engineering

1.4 Contexte, position et problématique

Problématique

Comment concevoir et industrialiser, dans l'environnement Amadeus, un système capable de transformer automatiquement des rapports financiers hétérogènes en KPI fiables, structurés et traçables, y compris lorsque leur reconstruction nécessite plusieurs variables, tout en réduisant les délais, les coûts et la dépendance à un prestataire externe ?

Mon travail s'est situé à l'interface entre les besoins métier, la Data Engineering et l'intelligence artificielle. J'ai travaillé avec les membres de l'équipe, les responsables produit et les équipes techniques impliquées dans l'infrastructure et le déploiement.

1.5 Objectifs de l'alternance

Les objectifs du projet ont été regroupés autour de cinq axes :

1. automatiser l'ingestion de rapports financiers hétérogènes ;
2. identifier et reconstruire les KPI à partir des informations disponibles ;
3. fiabiliser les résultats par des mécanismes de validation et de traçabilité ;
4. réduire les délais, les coûts et la dépendance au prestataire externe ;
5. industrialiser la solution afin de permettre son intégration et son exploitation dans l'écosystème Amadeus.

Ces objectifs couvrent ainsi l'ensemble du passage d'un document financier non structuré vers une donnée métier validée et exploitable. Les choix d'architecture et leur mise en œuvre sont détaillés dans la section suivante.

2. Analyse du travail réalisé

2.1 Présentation générale des missions

Mon alternance a progressivement évolué d'une phase de compréhension du besoin vers la conception puis l'industrialisation d'un système complet.

Les principales missions réalisées peuvent être regroupées en six blocs :

1. analyse du besoin et des documents financiers ;
2. conception de la chaîne d'ingestion multimodale ;
3. développement du système de retrieval ;
4. conception du moteur de reconstruction des KPI ;
5. validation et évaluation des résultats ;
6. industrialisation et monitoring.

TABLE 2 – Synthèse des principales missions

Mission	Objectif	Livrable principal
Analyse documentaire	Comprendre les formats, KPI et sources	Spécifications et modèle de données
Ingestion multi-modale	Transformer les PDF en représentation exploitable	Pipeline Vision / métadonnées
Retrieval	Identifier les fragments utiles	Retrieval hybride symbolique-sémantique
Reconstruction	Calculer les KPI manquants	Dependency graph et moteur de calcul
Validation	Évaluer la cohérence	Moteur de validation et métriques
Industrialisation	Rendre le système exploitable	Pipeline asynchrone, CI/CD, observabilité

2.2 Planning général

Le projet s'est déroulé de manière incrémentale. Chaque phase a permis d'identifier de nouvelles limitations et d'enrichir progressivement l'architecture.




FIGURE 2 – Diagrammes de Gantt : Période école/entreprise (01/09/2025 au 14/02/2026)




FIGURE 3 – Diagrammes de Gantt : Période entreprise à temps plein (17/02/2026 au 12/09/2026)

2.3 Spécifications du système

Le système couvre neuf KPI financiers et opérationnels, notés $k_1, \dots, k_9$, relatifs aux revenus, au trafic, à la capacité et aux ratios associés :

- k_1 : Passenger Revenue
- k_2 : Total Operating Revenue
- k_3 : RPK/RPM
- k_4 : Total Revenue per RPK/RPM
- k_5 : Passenger Revenue per RPK/RPM
- k_6 : ASK/ASM
- k_7 : Passenger Revenue per ASK/ASM
- k_8 : Total Revenue per ASK/ASM
- k_9 : Total Cost per ASK/ASM

Chaque KPI est associé à une période : Q_1, Q_2, Q_3, Q_4 désignent les quatre trimestres, H_1, H_2 les deux semestres et A l'année complète.

Selon le rapport et la période, un KPI peut être directement disponible ou reconstruit à partir de plusieurs variables. Les principales exigences de taux d'exactitude, de robustesse et de traçabilité sont synthétisées dans le tableau suivant.

Exigence	Description	Critère / mesure
Exigences fonctionnelles		
Ingestion documentaire	Traiter automatiquement des rapports PDF hétérogènes sans dépendre d'une structure fixe.	PDF → données
Analyse multimodale	Exploiter conjointement le texte, les tableaux, les graphiques et la structure visuelle.	Texte + Vision
Structuration	Produire des métadonnées et des résultats conformes à un schéma structuré.	JSON validé
Retrieval	Identifier les fragments pertinents et rechercher les informations complémentaires nécessaires.	Top- k pertinent
Reconstruction	Identifier les KPI explicites, calculables ou manquants et reconstruire ceux pouvant être calculés.	KPI final
Provenance	Conserver les sources ayant contribué à chaque valeur produite.	Document / page / chunk
Exigences non fonctionnelles		
taux d'exactitude	Maximiser la proportion de KPI correctement extraits ou reconstruits.	$A = \frac{N_{\text{corrects}}}{N_{\text{valus}}}$
Latence	Limiter le temps nécessaire au traitement complet d'un rapport.	$L_{\text{avg}} = \frac{1}{N} \sum_{i=1}^N t_i$
Coût	Maîtriser le coût d'exécution du pipeline, notamment celui des appels aux modèles.	$C_{\text{avg}} = \frac{1}{N} \sum_{i=1}^N C_i$
Traçabilité	Permettre d'expliquer et d'auditer l'origine de chaque KPI produit.	$KPI \rightarrow Source$
Robustesse	Tolérer les variations de mise en page, de terminologie, de qualité documentaire et les informations manquantes.	Formats variés

TABLE 3 – Synthèse des spécifications du système

2.4 Conception du système d'intelligence documentaire

Le système a été conçu comme une architecture modulaire séparant les tâches de perception documentaire, de recherche d'information, d'extraction, de reconstruction et de validation. Contrairement à une chaîne purement séquentielle, certains composants peuvent déclencher de nouvelles recherches ou réévaluer des résultats intermédiaires.

L'architecture générale peut être résumée par :

$$PDF \rightarrow Ingestion \rightarrow Extraction\ du\ contexte \rightarrow \{U_1, \dots, U_N\} \\ \rightarrow [Retrieval \rightarrow Extraction \rightarrow Graphe \rightarrow Calcul \rightarrow Validation]_{U_i}$$

Les modèles de langage mobilisés dans cette architecture reposent sur le paradigme Transformer, introduit par Vaswani et al. [1], dont le mécanisme d'attention constitue aujourd'hui un fondement des Large Language Models modernes. Cette séparation permet notamment de limiter le rôle des modèles probabilistes. Les LLM sont principalement utilisés pour la compréhension documentaire, la classification et la planification, tandis que les calculs et les contrôles critiques restent déterministes.




FIGURE 4 – Architecture générale simplifiée du système d'intelligence documentaire

Un agent correcteur est connecté transversalement aux principaux composants du pipeline. Son rôle détaillé sera présenté la section "Validation et mécanismes de correction".

2.4.1 Ingestion et compréhension multimodales

L'ingestion ne repose pas sur une simple transformation

$$PDF \rightarrow OCR \rightarrow Texte.$$

Les rapports financiers présentent des structures très différentes : certains contiennent principalement du texte natif, tandis que d'autres intègrent des pages scannées, des tableaux, des graphiques ou des éléments dont l'information textuelle n'est pas directement accessible.

Le système applique donc plusieurs stratégies de parsing selon le type et la structure du document. Une

première extraction récupère le contenu textuel directement accessible à l'aide de bibliothèques adaptées au format du PDF.

En parallèle, les éléments nécessitant une analyse visuelle sont identifiés. Les tableaux sont notamment localisés à l'aide de Table Transformer (TATR), une architecture utilisée pour la détection et l'analyse de structures tabulaires dans des documents [2], tandis que les zones graphiques ou non directement exploitables peuvent être rasterisées puis traitées par OCR ou par un modèle Vision-Language.

Le processus peut être représenté de manière simplifiée par :

$$PDF \rightarrow \begin{cases} \text{Parsing natif} & \rightarrow T_{\text{native}} \\ \text{Détection de tableaux} & \rightarrow T_{\text{table}} \\ \text{OCR / Vision} & \rightarrow T_{\text{visual}} \end{cases}$$

Les informations récupérées ne sont pas conservées comme des flux indépendants. Les sorties issues de l'OCR, des tableaux et de l'analyse visuelle sont réintroduites à leur position logique dans le texte parsé afin de construire une représentation documentaire consolidée : $T_{\text{combined}} = \text{Merge}(T_{\text{native}}, T_{\text{table}}, T_{\text{visual}})$

Cette étape permet de conserver autant que possible la structure et le contexte du document tout en intégrant des informations qui auraient été perdues avec un parsing textuel classique.

Chaque page est ensuite associée à une représentation enrichie : $Page_i \rightarrow (T_i, V_i, M_i)$

où T_i représente le contenu textuel consolidé, V_i les informations issues de l'analyse visuelle et M_i les métadonnées associées.

Afin de respecter les contraintes de taille imposées aux modèles multimodaux, la rasterisation adapte également la résolution jusqu'à vérifier : $S(p, d) \leq S_{\text{max}}$

où p représente la page, d sa résolution et S_{max} la taille maximale autorisée.

Les métadonnées extraites comprennent notamment les entités, les périodes, les KPI candidats ainsi que des informations utiles au retrieval. Elles sont ensuite consolidées au niveau du document.

Chaque unité indexée contient finalement : $C_i = (text_i, page_i, document_i, metadata_i, embedding_i)$

Cette représentation conserve simultanément le contenu, sa représentation sémantique et sa provenance documentaire.

2.4.2 Partitionnement initial par compagnie et période

Un rapport PDF ne porte pas nécessairement sur une seule compagnie aérienne ni sur une seule période. Au contraire, un même document peut contenir des informations relatives à plusieurs compagnies et présenter simultanément plusieurs périodes financières. Or, le système doit produire un jeu de KPI distinct pour chaque compagnie appartenant au périmètre métier traité et pour chacune des périodes concernées.

Un seul PDF peut ainsi conduire à plusieurs sorties indépendantes. Par exemple, un rapport peut mentionner *Lufthansa Group*, *SWISS*, *Brussels Airlines*, *Eurowings* ou encore *Austrian Airlines*, tout en contenant des données pour les périodes Q4, H2 et l'exercice annuel. Si le périmètre configuré pour le traitement ne retient que *Lufthansa Group* et *SWISS*, le système doit alors produire six résultats distincts :

(Lufthansa Group, $Q4$), (Lufthansa Group, $H2$), (Lufthansa Group, A),
 (SWISS, $Q4$), (SWISS, $H2$), (SWISS, A).

Cette séparation est réalisée très tôt dans la chaîne de traitement, immédiatement après l'extraction textuelle du PDF. Un premier passage par un LLM analyse le contenu obtenu afin d'identifier les différentes unités métier présentes dans le document. Chaque unité est décrite par :

$$U_i = (\text{nom_compagnie}, \text{code_IATA}, \text{code_ICAO}, \text{période}, \text{année})$$

Le nom de la compagnie et ses identifiants permettent de rattacher les informations à l'entité correcte, tandis que la période et l'année définissent le contexte temporel dans lequel les KPI devront être extraits ou reconstruits. Les unités ne correspondant pas aux compagnies configurées dans le périmètre du système sont écartées à ce stade.




FIGURE 5 – Détection des contextes métier et génération des unités de traitement

Si l'on note A le nombre de compagnies retenues et P le nombre de périodes à traiter, le système peut donc générer : $N = A \times P$

flux de traitement à partir d'un même rapport. Dans l'exemple précédent, $A = 2$ et $P = 3$, d'où : $N = 6$.

Le point essentiel est que ces flux ne constituent pas de simples variantes d'une même exécution. À partir de cette séparation, chacun est traité comme une chaîne totalement indépendante, avec son propre contexte compagnie-période-année.

Ainsi, le retrieval, la projection dans l'espace des vecteurs signés, la recherche complémentaire, le classement des fragments, l'extraction structurée, la construction du graphe de dépendances, les calculs et la validation sont tous exécutés séparément pour chaque unité U_i .




FIGURE 6 – Exécution indépendante de la chaîne aval pour chaque unité de traitement

Dans toute la suite de cette section, le fonctionnement du retrieval, du vecteur signé, de la reconstruction et de la validation est donc présenté **à l'échelle d'un seul flux de traitement** U_i . Le même processus est ensuite exécuté indépendamment pour chacune des autres unités générées à partir du document.

2.5 Retrieval hybride

Le paradigme Retrieval-Augmented Generation (RAG) combine un mécanisme de recherche d'information avec un modèle génératif afin d'exploiter des connaissances externes [3]. Dans ce type d'approche, la recherche sémantique s'appuie notamment sur des représentations vectorielles permettant d'estimer la proximité entre une requête et des fragments documentaires [4].

Cette approche constitue une amélioration importante par rapport à une extraction reposant uniquement sur le parsing ou l'OCR, mais elle reste insuffisante dans le cas étudié. Les embeddings indiquent qu'un fragment est sémantiquement proche d'une requête, sans permettre de déterminer si les informations qu'il contient suffisent réellement à reconstruire le KPI.

Pour un KPI défini par : $K_i = f(x_a, x_b)$

un fragment peut ainsi être indispensable au calcul sans contenir directement le KPI recherché. À l'inverse, un fragment très proche sémantiquement peut ne contenir qu'une partie des variables nécessaires. La proximité sémantique ne garantit donc pas la capacité de reconstruction : Similarity $\neq$ Computability

L'enjeu n'est alors plus uniquement de retrouver les fragments les plus similaires, mais d'identifier un ensemble d'informations permettant de rendre le KPI calculable. Pour répondre à cette limite, le système développé complète la recherche sémantique par une représentation symbolique des informations nécessaires à chaque KPI.

“ latex

2.5.1 Représentation symbolique par vecteur signé

La représentation symbolique part d'un constat simple : un KPI n'est pas toujours présent directement dans un fragment. Il peut également être reconstruit à partir de deux informations complémentaires,

éventuellement situées dans des fragments différents.

Pour un KPI cible K_i , on considère donc sa présence directe ainsi que les différents couples de variables pouvant permettre sa reconstruction. Une relation métier peut par exemple s'écrire $K_i = f(x_a, x_b)$, où x_a et x_b peuvent être des variables financières ou d'autres KPI déjà disponibles. Un même KPI peut disposer de plusieurs chemins possibles, par exemple $K_i = f_1(x_1, x_2)$ ou $K_i = f_2(x_3, x_4)$.

Le retrieval ne consiste donc plus uniquement à rechercher un fragment mentionnant K_i , mais à retrouver les deux composantes d'au moins un de ces chemins de reconstruction.

Des métadonnées documentaires vers une représentation symbolique Lors de l'analyse documentaire, chaque fragment c_i est associé à des métadonnées structurées. Pour le vecteur signé, seules les informations utiles au KPI recherché sont conservées. On note ainsi $M_v(c_i) = \{\text{KPI cible ou variables utiles détectés dans } c_i\}$.

Ces informations sont projetées dans un espace de variables candidates propre au KPI, noté $\mathcal{D}_{K_i} = (K_i, x_1, x_2, \dots, x_d)$. Cet espace regroupe le KPI cible et les variables susceptibles d'intervenir dans ses différents chemins de reconstruction.

Chaque fragment est alors représenté par un vecteur symbolique $v_{K_i}(c_i) \in \{-1, 0, +1, \emptyset\}^{d+1}$, où :

$$\begin{cases} 0 & \text{le KPI cible est directement présent,} \\ +1 & \text{une composante d'une relation est présente,} \\ -1 & \text{sa composante complémentaire est présente,} \\ \emptyset & \text{l'information correspondante n'est pas détectée.} \end{cases}$$

Les signes $+1$ et -1 ne correspondent pas aux coefficients numériques d'une formule. Ils codent uniquement la complémentarité entre les deux variables d'une même relation de reconstruction.

Pour une relation donnée r , retrouver ses deux composantes produit symboliquement $+1 + (-1) = 0$. Cette annulation n'est évaluée qu'entre deux variables appartenant à la même relation : une composante provenant d'un chemin f_1 ne peut donc pas annuler une composante appartenant à un autre chemin f_2 .

Le symbole 0 joue ainsi le rôle d'un état de complétude : il indique soit que le KPI est directement présent, soit que les deux informations nécessaires à un chemin de reconstruction ont été retrouvées.

Exemple de projection Considérons le KPI *Passenger Revenue*, pouvant par exemple être reconstruit par $\text{PassengerRevenue} = \text{TotalRevenue} - \text{TrafficRevenue}$.

L'espace correspondant peut être noté $\mathcal{D}_{PR} = (\text{PassengerRevenue}, \text{TotalRevenue}, \text{TrafficRevenue})$, avec la signature symbolique $(0, +1, -1)$.

Si un fragment c_1 contient directement *Passenger Revenue*, alors $M_v(c_1) = \{\text{PassengerRevenue}\}$ et $v_{PR}(c_1) = (0, \emptyset, \emptyset)$. Le KPI est disponible et aucune recherche complémentaire n'est nécessaire.

Supposons maintenant qu'un fragment c_2 contienne uniquement *Total Revenue*. On obtient $v_{PR}(c_2) = (\emptyset, +1, \emptyset)$. Le système sait alors que la composante complémentaire de cette même relation doit encore être retrouvée.

Si un fragment c_3 contient ensuite *Traffic Revenue*, $v_{PR}(c_3) = (\emptyset, \emptyset, -1)$. Les deux fragments couvrent alors le couple associé à cette relation et l'agrégation symbolique donne $+1 + (-1) = 0$. Le système peut donc considérer que les informations nécessaires à la reconstruction ont été retrouvées.

Le même principe s'applique lorsqu'un KPI possède plusieurs chemins. Si $K = f_1(x_1, x_2)$ ou $K = f_2(x_3, x_4)$, retrouver (x_1, x_2) suffit à compléter le premier chemin, tandis que retrouver (x_3, x_4) complète le second. En revanche, retrouver x_1 et x_4 ne produit aucune complétude, car ces variables appartiennent à deux relations différentes.

Recherche guidée par les informations manquantes Cette représentation permet de transformer une recherche passive en une recherche guidée par les informations manquantes. Lorsqu'une composante $+1$ est retrouvée pour une relation donnée, le système recherche son complément -1 dans cette même relation, et réciproquement.

Les principaux états sont donc : $0 \Rightarrow$ KPI directement disponible, $+1 \Rightarrow$ recherche de la composante complémentaire, $-1 \Rightarrow$ recherche de son complément, et $+1 + (-1) = 0 \Rightarrow$ chemin de reconstruction complet.

Pour un ensemble de fragments $C = \{c_1, \dots, c_m\}$, le retrieval cherche ainsi non seulement les fragments les plus proches sémantiquement, mais un ensemble couvrant les informations nécessaires à au moins un chemin de reconstruction :

$$\text{Retrieval}(K) = \text{Pertinence sémantique} + \text{Complétude des informations}$$

Les embeddings servent à identifier les fragments pertinents, tandis que la représentation signée permet de suivre la présence des variables complémentaires et de décider si une recherche supplémentaire est nécessaire.

Cette représentation ne contient cependant pas la sémantique de la formule : elle sait que deux variables appartiennent au même chemin de reconstruction, mais ne détermine ni l'opération à appliquer, ni les conversions éventuelles, ni l'ordre des calculs. Elle répond uniquement à la question « *Ai-je retrouvé les informations nécessaires pour reconstruire le KPI ?* »

Le graphe de dépendances intervient ensuite pour exploiter ces informations. Il décrit les formules disponibles, les dépendances entre variables et l'ordre dans lequel elles doivent être résolues. Il répond donc à une question différente : « *Comment utiliser ces informations pour calculer le KPI ?* » “

2.5.2 Catégorisation et classement des fragments

Après la projection dans l'espace symbolique, les fragments candidats sont répartis dans des catégories de priorité selon les informations qu'ils contiennent pour le KPI recherché. On définit la hiérarchie $A \succ B \succ C$.

La catégorie A regroupe les fragments contenant directement le KPI cible, c'est-à-dire ceux pour lesquels le vecteur contient 0. Ils constituent donc les résultats prioritaires puisqu'aucune reconstruction n'est nécessaire.

La catégorie B regroupe les fragments contenant, pour une même relation de reconstruction, les deux composantes complémentaires $+1$ et -1 . Le KPI n'est pas explicitement présent, mais les informations nécessaires à son calcul sont déjà réunies dans le fragment.

La catégorie C correspond enfin aux fragments ne contenant qu'une seule composante, $+1$ ou -1 . Ils sont pertinents mais incomplets et nécessitent une recherche complémentaire afin de retrouver la composante manquante.

Les catégories constituent le premier niveau de classement. Ainsi, un fragment de catégorie A reste prioritaire par rapport à un fragment de catégorie B , lui-même prioritaire par rapport à un fragment de catégorie C , indépendamment de leur score numérique.

L'utilisation de modèles de langage pour réévaluer la pertinence de résultats issus d'un moteur de recherche a notamment été étudiée dans le cadre du re-ranking par LLM [5].

Dans notre système, ce signal n'est cependant pas utilisé seul. À l'intérieur d'une même catégorie, les fragments sont ordonnés à partir d'un score combinant une estimation d'importance produite par un LLM et leur proximité sémantique avec la requête :

$$Score(c, q) = I(c) + \lambda \cos(E_q, E_c)$$

où :

- c représente le fragment candidat ;
- q représente la requête associée au KPI ;
- E_q est l'embedding de la requête ;
- E_c est l'embedding du fragment ;
- $\cos(E_q, E_c)$ mesure leur similarité sémantique ;
- $I(c)$ est un score d'importance attribué au fragment par un LLM ;
- λ contrôle le poids relatif de la similarité sémantique.

Le score $I(c)$ est produit lors de l'analyse documentaire. Le LLM évalue l'importance du fragment sur une échelle allant de -10 à 10 en fonction de son contenu et de son intérêt potentiel pour l'extraction des KPI.

Le classement est donc hiérarchique : $Rank(c) = (Category(c), Score(c, q))$

La catégorie est évaluée en premier, puis le score permet de départager les fragments appartenant à une même catégorie.

Un seuil minimal τ est également appliqué : $Score(c, q) \geq \tau$

Les fragments dont le score est inférieur au seuil sont éliminés, y compris lorsqu'ils appartiennent à une catégorie de priorité élevée.

Le retrieval combine ainsi quatre informations complémentaires :

Signed Vector + Category + LLM Importance + Semantic Similarity

auxquelles s'ajoutent les contraintes de période et de compagnie.

2.6 Extraction structurée et reconstruction des KPI

Une décision importante de l'architecture consiste à séparer **extraction** et **calcul**.

À partir des fragments sélectionnés par le système de retrieval, le modèle extrait les informations disponibles sans effectuer directement les opérations numériques nécessaires à la reconstruction.

Chaque KPI est alors associé à un état : $state(K_i) \in \{explicit, computable, missing\}$

où :

- *explicit* indique que la valeur est directement disponible ;
- *computable* indique que les variables nécessaires au calcul ont été identifiées ;
- *missing* indique qu'au moins une information reste absente.

Les résultats sont générés sous une forme structurée contenant notamment l'identifiant du KPI, sa valeur éventuelle, sa période, son statut, ses dépendances et sa provenance.

2.6.1 Graphe de dépendances et construction du contexte de résolution

Après l'extraction structurée, chaque KPI est associé à un ensemble d'informations décrivant son état, les variables déjà disponibles, leur provenance ainsi que les relations permettant éventuellement de le reconstruire. Le graphe de dépendances complète cette représentation en explicitant les différents chemins de calcul possibles.

On note :

$$G = (V, E)$$

où V représente les KPI et les variables intermédiaires, tandis que E représente leurs relations de dépendance.

Le graphe n'effectue donc pas directement les calculs. Il fournit au composant de résolution une représentation structurée des possibilités disponibles. Pour un KPI K_i , plusieurs chemins peuvent par exemple exister :

$$K_i = f_1(x_1, x_2) \quad \text{ou} \quad K_i = f_2(K_j, x_3)$$

La sortie du graphe est ensuite combinée avec le JSON produit lors de l'extraction structurée. L'agent de résolution reçoit ainsi un contexte fortement contraint contenant notamment :

$$C_{K_i} = \{\text{valeurs disponibles, formules possibles, dépendances, sources, unités, devises, métriques, période}\}$$

Les fragments sources ayant conduit à l'extraction sont également conservés dans ce contexte. L'objectif est de fournir à l'agent uniquement les informations utiles à la résolution du KPI, plutôt que de lui transmettre de nouveau l'ensemble du document.

Le graphe joue ainsi le rôle de structure de raisonnement : il indique quelles voies de reconstruction sont possibles et quelles dépendances restent à résoudre. La décision sur la manière de les résoudre est ensuite prise par l'agent présenté dans la section suivante.

2.6.2 Agent de résolution et orchestration itérative des outils

La reconstruction finale des KPI est pilotée par un agent de résolution. À partir du contexte C_{K_i} , celui-ci analyse les chemins proposés par le graphe, identifie les informations manquantes et construit un plan d'actions.

Contrairement à une exécution statique, ce plan peut évoluer au cours de la résolution. Après chaque

action, son résultat est réinjecté dans le contexte, puis l'agent raisonne de nouveau afin de déterminer l'étape suivante :

$$C_t \rightarrow \text{Plan}_t \rightarrow \text{Tool}_t \rightarrow \text{Result}_t \rightarrow C_{t+1}$$

Ce cycle est répété jusqu'à ce qu'un chemin de calcul soit entièrement résolu ou qu'aucune reconstruction fiable ne soit possible.

L'agent dispose principalement de trois familles d'outils :

$$T = \{\text{Math}, \text{History}, \text{Retrieval}\}$$

- **Math** exécute les formules déterministes ainsi que les conversions nécessaires de devise, d'unité ou de métrique ;
- **History** interroge les données historiques disponibles, notamment lorsque la reconstruction nécessite une valeur provenant d'une autre période ;
- **Retrieval** relance une recherche documentaire ciblée avec une nouvelle requête lorsqu'une dépendance n'a pas été retrouvée dans le contexte initial.

Considérons par exemple un KPI K_4 pour lequel le graphe propose initialement : $K_4 = \frac{x_1}{x_2}$

Si x_2 est absent, l'agent peut explorer un autre chemin disponible : $K_4 = \frac{K_1}{K_3}$

Supposons cependant que K_1 soit également manquant. Le graphe indique que ce KPI est sommable dans le temps et que la période recherchée est $H1$. L'agent peut alors déduire : $K_1^{H1} = K_1^{Q1} + K_1^{Q2}$

Il planifie dans ce cas la récupération de K_1^{Q1} et K_1^{Q2} à partir des données historiques. Cette opération est exécutée par le moteur d'accès aux données, basé sur les résultats historiques persistés en CSV.

Une fois ces valeurs récupérées, elles sont ajoutées au contexte. L'agent peut alors planifier le calcul de K_1^{H1} , puis reprendre la résolution de K_4 .

Le moteur mathématique ne se limite pas à appliquer une opération arithmétique. Avant le calcul, l'agent doit également vérifier la compatibilité des valeurs utilisées et planifier, lorsque nécessaire, les transformations dans le bon ordre :

valeurs brutes → normalisation des métriques → conversion des unités → conversion monétaire → calcul

Les transformations elles-mêmes restent déterministes ; le rôle de l'agent est de sélectionner et d'ordonner les opérations nécessaires.

La résolution d'un KPI peut donc nécessiter plusieurs itérations combinant raisonnement, recherche documentaire, accès aux données historiques et calcul. Le LLM agit comme orchestrateur du processus, tandis que les opérations vérifiables sont déléguées à des composants spécialisés.

Cette séparation permet de conserver la flexibilité du raisonnement par LLM sans lui confier directement les opérations numériques critiques, ce qui améliore la reproductibilité et la traçabilité du résultat final.

2.7 Validation et mécanismes de correction

La validation combine des contrôles déterministes sur le schéma, les unités, les périodes et la cohérence mathématique. Lorsqu'une anomalie peut être corrigée sans ambiguïté, une règle déterministe est appliquée directement.

Anomalie	Correction
Format ou unité invalide	Normalisation déterministe
Période ou variable manquante	Retrieval ciblé
Incohérence arithmétique	Recalcul / rejet
Erreur d'interprétation	Corrector Agent

TABLE 4 – Principaux mécanismes de validation et de correction

Les erreurs qui ne peuvent pas être résolues de manière déterministe déclenchent un *Corrector Agent*. C'est notamment le cas lorsqu'un LLM situé en amont a mal interprété un document, une variable ou une relation entre plusieurs informations.

À partir de l'erreur observée et des traces du pipeline, cet agent identifie le composant probablement responsable puis demande uniquement la réexécution ou la correction de cette étape : *Error* → *Diagnosis* → *Targeted Correction* → *Retry*

Ce mécanisme évite de relancer l'ensemble du pipeline et permet de corriger des erreurs sémantiques qui ne peuvent pas être détectées ou réparées par de simples règles.

2.8 Industrialisation et observabilité

Le prototype a progressivement été transformé en pipeline industrialisable afin de permettre son exécution de manière reproductible dans l'environnement Amadeus. La chaîne d'exécution repose sur un workflow automatisé allant du dépôt des rapports financiers jusqu'à la génération des résultats structurés.



FIGURE 7 – Chaîne d'exécution industrialisée du pipeline

Les rapports PDF sont d'abord déposés dans Amazon S3. Leur présence déclenche un job Jenkins chargé de lancer le traitement. Plusieurs pipelines peuvent être exécutés en parallèle lorsque plusieurs rapports sont à traiter.

Afin de respecter les limites imposées aux appels aux modèles, l'exécution repose sur un mécanisme hiérarchique de *token buckets*. Chaque pipeline possède un quota local régulant ses propres appels LLM, tandis qu'un quota global partagé contrôle la consommation cumulée de l'ensemble des pipelines exécutés en parallèle. Un appel n'est effectué que lorsque les deux niveaux disposent d'une capacité suffisante ; sinon, il est différé jusqu'au renouvellement du quota.

Cette régulation permet de conserver le parallélisme du traitement tout en limitant les pics de consommation et les erreurs liées aux *rate limits*. Les résultats finaux sont ensuite exportés au format CSV et persistés

dans Amazon S3.




FIGURE 8 – pipelines parallèles avec limitation de débit hiérarchique

Chaque traitement possède également un état explicite permettant de suivre son évolution :

[Pending → *Processing* → *Completed*]

ou, en cas d'erreur :

[*Processing* → *Failed* → *Retry*]

Les documents bruts, métadonnées, résultats intermédiaires et logs sont persistés afin de permettre la reprise sur erreur, le diagnostic des échecs et l'audit des traitements.

La conteneurisation garantit la reproductibilité des environnements, tandis que la chaîne CI/CD automatise les principales étapes du cycle de déploiement :

[Code → *Build* → *Test* → *Deploy*]

Enfin, l'observabilité complète cette architecture en suivant notamment :

[O=latency, tokens, errors, throughput, cost]

Ces métriques permettent de suivre les performances techniques et économiques du pipeline, notamment le temps moyen de traitement, le taux d'erreur, le nombre de retries, le débit de traitement ainsi que le coût associé aux appels aux modèles.

2.9 Résultats et perspectives

L'évaluation repose sur les données historiques disponibles avant 2025, utilisées comme *ground truth*. Pour chaque combinaison compagnie-période, les KPI produits par le pipeline sont comparés aux valeurs de référence après normalisation.

La métrique principale est : $\text{taux d'exactitude} = \frac{N_{\text{KPI corrects}}}{N_{\text{KPI valus}}}$

L'étude a porté sur **300 rapports PDF** provenant de plusieurs compagnies et présentant des structures documentaires variées. Comme un même document peut contenir plusieurs compagnies ou plusieurs périodes, ces rapports ont généré **525 sorties indépendantes**. Chaque sortie comprenant les neuf KPI définis dans les spécifications, l'évaluation porte au total sur : $525 \times 9 = 4725 \text{ KPI}$

Cette évaluation sur des données réelles permet de couvrir plusieurs années, compagnies et configurations documentaires sans recourir à des données artificielles, difficiles à générer de manière cohérente avec l'ensemble des dépendances métier.

Les résultats montrent un **taux d'exactitude comprise entre 99,08 % et 100 %** selon les compagnies testées. Cette métrique est complétée par le temps moyen de traitement et le coût d'exécution.

Les principaux cas d'échec concernent les erreurs de période, les documents bruités, les informations manquantes et certaines dépendances mal identifiées. Ces limites ont notamment conduit à l'ajout du retrieval complémentaire, de la validation déterministe et du mécanisme de correction ciblée.

Les principales perspectives concernent désormais l'utilisation de modèles plus spécialisés, l'optimisation du routage, la réduction du contexte transmis, l'amélioration du graphe de dépendances et l'automatisation continue de l'évaluation. Les résultats obtenus sont présentés dans la Figure 9.

Airline	Accuracy	Cost Range per period	Avg Runtime
Jet Blue	100%	1.14\$ - 1.75\$	~9min
British airways	100%	0.80\$ - 1.60\$	~5.75min
Vueling	100%	0.80\$ - 1.60\$	~5.57min
Ein	99.97%	0.80\$ - 1.60\$	~5.75min
United Airlines Holdings	99.88%	1.79\$ - 3.99\$	~13min
Hawaiian Holdings	99.83%	1.13\$ - 1.92\$	~10min
Alaska Airlines	99.73%	0.94\$ - 1.49\$	~7min
Delta Airlines	99.70%	1.06\$ - 1.75\$	~8min
Air Canada Airlines	99.45%	1.41\$ - 4.53\$	~11min
American Airlines	99.08%	1.63\$ - 3.07\$	~12min

FIGURE 9 – Résultats expérimentaux : taux d'exactitude, coût et temps moyen de traitement

Les expérimentations montrent un **taux d'exactitude compris entre 99,08 % et 100 %** selon les compagnies testées. Le temps moyen de traitement varie d'environ **5,6 à 13 minutes par sortie**, tandis que le coût d'exécution reste de l'ordre de quelques dollars, en fonction de la taille et de la complexité du rapport ainsi que du nombre d'appels aux modèles nécessaires.

À titre de comparaison, le processus précédent reposait sur un prestataire externe, avec un taux d'exactitude estimé à environ **95 %**, un délai de traitement généralement compris entre **une et deux semaines** et un coût d'environ **30 \$ par Airline-period traité**. Ce processus offrait également une traçabilité limitée sur l'origine des valeurs produites et sur les étapes ayant conduit au résultat final.

La solution développée améliore ainsi simultanément le taux d'exactitude, le délai de traitement, le coût et la traçabilité des KPI produits. L'internalisation du processus permet également à l'équipe de mieux contrôler son évolution, son évaluation et ses mécanismes de correction.

Les principales perspectives concernent désormais l'utilisation de modèles plus spécialisés, l'optimisation du routage des modèles, la réduction du contexte transmis, l'amélioration du graphe de dépendances et

l'automatisation continue de l'évaluation.

2.10 Difficultés, limites et regard critique

Malgré les performances obtenues, plusieurs limites subsistent. La première concerne la dépendance aux interprétations produites en amont par les modèles : une erreur sur une période, une variable ou une relation peut rester cohérente en apparence et se propager jusqu'au moteur de reconstruction. Les mécanismes de validation réduisent ce risque sans pouvoir l'éliminer totalement.

La seconde limite concerne la généralisation. L'évaluation repose sur les rapports historiques disponibles et couvre plusieurs compagnies et structures documentaires, mais elle ne garantit pas un comportement identique face à un format totalement nouveau ou particulièrement bruité.

Enfin, l'architecture obtenue est plus robuste qu'un pipeline RAG simple, mais également plus complexe à maintenir et à optimiser. Le principal compromis porte donc sur le niveau de complexité réellement nécessaire pour augmenter la fiabilité sans multiplier inutilement les appels aux modèles, la latence et le coût. Les prochaines évolutions devront ainsi privilégier la simplification et la spécialisation des composants lorsque cela est possible.

3. Entretien métier

Dans le cadre de cette alternance, j'ai réalisé un entretien avec mon tuteur afin de mieux comprendre le métier d'Ingénieur Data chez Amadeus, les compétences qu'il mobilise et ses perspectives d'évolution.

Son rôle consiste principalement à concevoir, développer et maintenir des solutions Big Data destinées aux produits déployés pour les clients d'Amadeus. Il intervient sur l'ensemble du cycle de vie des données, depuis leur ingestion jusqu'à leur exploitation. Ses missions couvrent le développement de pipelines robustes et scalables, l'amélioration continue des solutions existantes ainsi que leur maintien en condition opérationnelle. Le suivi de la production et la résolution d'incidents occupent également une place importante afin de garantir la fiabilité des services.

Sur le plan organisationnel, nous appartenons à la même équipe. Celle-ci est désormais encadrée par Mireille Boyer, qui en a repris le management en mai 2026. Auparavant, Jérémie Montiel, dont le rôle principal est celui de *Data Principal*, avait assuré cette fonction par intérim pendant près d'un an. Le travail quotidien s'inscrit dans une organisation Agile avec des *daily meetings*, des points de suivi, des *iteration reviews* et des PI Plannings. Le métier implique également des interactions régulières avec les équipes produit, les Data Scientists, les architectes et d'autres équipes techniques.

Concernant son parcours, mon tuteur a suivi une classe préparatoire en mathématiques et informatique, puis une école d'ingénieurs spécialisée en informatique. Il a ensuite réalisé une alternance chez EDF avant de rejoindre Amadeus. Sur le plan technique, son métier nécessite notamment une bonne maîtrise d'Apache Spark, de Scala et de Python. Bash est utilisé pour le scripting et l'automatisation, tandis que les environnements cloud comme AWS ou Azure occupent une place croissante. Jenkins et Git permettent enfin d'industrialiser les développements à travers les pratiques de CI/CD. Les principes de partitionnement, parallélisation et optimisation des performances restent également essentiels.

Ces compétences techniques doivent être complétées par plusieurs qualités humaines. L'autonomie est nécessaire pour résoudre des problèmes complexes, tandis que la capacité d'adaptation permet de suivre l'évolution rapide des technologies et des besoins. L'esprit d'équipe est également important, notamment

lors des revues de code, du partage de connaissances ou de la résolution collective d'incidents.

Selon lui, l'un des principaux intérêts du métier réside dans la diversité des problèmes rencontrés et le challenge intellectuel associé à leur résolution. L'environnement Amadeus permet de travailler sur des systèmes à grande échelle soumis à de fortes contraintes de performance et de disponibilité. Cela oblige à trouver un équilibre entre innovation technique, scalabilité, coût et fiabilité en production.

L'intelligence artificielle générative devrait également faire évoluer ce métier. Certaines tâches répétitives liées au monitoring, à la maintenance ou à l'analyse d'incidents pourraient progressivement être assistées par des agents intelligents. Le rôle de l'ingénieur pourrait alors se concentrer davantage sur la conception d'architectures, l'optimisation des systèmes et les problématiques nécessitant une expertise technique avancée.

À moyen terme, son objectif est d'évoluer vers un poste d'architecte Big Data afin d'intervenir davantage sur la conception globale de plateformes et de pipelines à grande échelle. Pour un jeune ingénieur souhaitant suivre une trajectoire similaire, il recommande d'évoluer dans un environnement technique exigeant, de travailler avec des profils expérimentés et de conserver une forte curiosité. Dans un domaine en évolution rapide, la capacité à apprendre continuellement reste selon lui aussi importante que la maîtrise d'une technologie particulière.

4. Bilan personnel

Cette alternance a constitué une expérience particulièrement formatrice, aussi bien sur le plan technique que professionnel. La mission qui m'a été confiée était sensiblement différente des sujets abordés dans mon cursus académique. Si ma formation m'avait apporté de solides bases en informatique et en intelligence artificielle, une grande partie des concepts nécessaires au projet relevait plus spécifiquement de l'ingénierie moderne des systèmes de Generative AI.

J'ai ainsi dû approfondir de manière autonome le fonctionnement des Large Language Models (LLM) : tokens, fenêtre de contexte, mécanismes d'attention, paramètres d'inférence, prompt engineering et génération structurée. J'ai également développé mes compétences sur les architectures RAG, les embeddings, les bases de données vectorielles, les Vision-Language Models (VLM), les systèmes agentiques, le tool calling et les graphes de dépendances. Cette montée en compétences concernait également l'industrialisation avec AWS, Amazon Bedrock, S3, Docker, Jenkins, CI/CD, le déploiement et l'observabilité.

Certains de ces concepts étaient entièrement nouveaux pour moi. J'avais néanmoins commencé à me former de manière autonome avant mon arrivée, notamment durant l'été, car la Generative AI était un domaine qui m'intéressait particulièrement. Cette expérience m'a surtout fait comprendre qu'un ingénieur doit continuellement apprendre et s'adapter, particulièrement dans un domaine aussi évolutif que l'intelligence artificielle.

Savoir-faire et savoir-être développés

J'ai surtout appris à aborder un problème complexe comme un véritable problème d'ingénierie. Au début du projet, j'ai exploré différentes architectures, réalisé le *system design*, comparé les technologies et les modèles disponibles et étudié leurs avantages, leurs limites et leurs coûts. Après validation de l'architecture, j'ai progressivement implémenté et testé chaque composant avant de les intégrer dans un pipeline complet.

Cette démarche m'a permis de développer davantage de rigueur dans la définition des hypothèses, les tests, l'analyse des erreurs et l'amélioration itérative du système. La solution finale ne repose pas simplement sur un LLM, mais combine traitement multimodal, retrieval sémantique et symbolique, RAG, graphes de dépendances, calcul déterministe, validation et monitoring.

Sur le plan du savoir-être, j'ai développé mon autonomie, ma capacité d'adaptation et ma communication technique. Les *daily meetings* m'ont appris à présenter clairement les avancées, les prochaines étapes et les blocages rencontrés. L'équipe m'a beaucoup accompagné, notamment sur l'environnement Amadeus, AWS, l'infrastructure, le déploiement et les procédures internes, tout en me laissant une forte autonomie. J'ai également particulièrement apprécié l'intégration humaine dans l'équipe et les activités réalisées ensemble.

Apports réciproques et atteinte des objectifs

L'un des objectifs principaux de mon alternance était de déterminer si l'automatisation de l'extraction et de la reconstruction de KPIs financiers à partir de rapports PDF était réellement réalisable. Le processus existant dépendait d'un prestataire externe et présentait plusieurs limites : délais importants, erreurs humaines, manque de visibilité et difficultés de communication.

Le problème était particulièrement adapté à la Generative AI puisque les données étaient contenues dans des documents non structurés mêlant texte, tableaux et graphiques. Certains KPIs devaient également être reconstruits à partir d'informations réparties sur différentes pages ou périodes.

J'ai apporté à l'équipe Data Engineering une expertise complémentaire en intelligence artificielle. Ma connaissance des mécanismes internes des LLM m'a permis d'aller au-delà d'une simple utilisation de modèles ou d'agents et de contrôler plus finement leur comportement, leur contexte, leur génération, leurs outils et leurs mécanismes de retrieval.

Le prototype a progressivement évolué vers une architecture complète intégrant ingestion multimodale, retrieval hybride, génération structurée, calcul, validation et observabilité. La faisabilité ayant été démontrée et la solution ayant évolué vers une architecture déployable, je considère que les principaux objectifs de mon alternance ont été atteints.

Organisation, outils et évolution professionnelle

La gestion du temps a suivi plusieurs phases : compréhension du problème et recherche, conception de l'architecture, développement et tests des composants, intégration puis industrialisation. J'ai travaillé de manière incrémentale en validant chaque composant avant de l'intégrer au système global, ce qui a permis d'identifier rapidement les erreurs et les limites.

Par rapport au début de l'alternance, je maîtrise beaucoup mieux AWS, notamment Bedrock et S3, ainsi que Jenkins, Docker et les principes de CI/CD. J'ai également fortement progressé sur les LLM, VLM, RAG, embeddings, bases vectorielles, architectures agentiques et systèmes d'observabilité. La productionisation m'a également confronté aux problématiques de reproductibilité, de traitements asynchrones, de persistance, de gestion des erreurs et de scalabilité.

Cette expérience a précisé mon orientation professionnelle et confirmé mon intérêt pour des postes à l'intersection de l'intelligence artificielle, de la Generative AI et du software/data engineering. Je souhaiterais également travailler dans ce type d'entreprise, car j'ai particulièrement apprécié la combinaison entre autonomie, responsabilités, accompagnement et complexité technique des projets.

Enfin, cette alternance m'a permis de comprendre qu'un ingénieur ne se définit pas uniquement par les technologies qu'il maîtrise à un instant donné, mais surtout par sa capacité à apprendre, à s'adapter et à transformer un problème complexe en une solution fiable et industrialisable.

5. Projet professionnel

Cette alternance a eu un rôle important dans la construction de mon projet professionnel, car elle m'a permis de confronter les connaissances acquises durant ma formation à un projet réel, avec des contraintes techniques, opérationnelles et industrielles. Avant cette expérience, je savais déjà que je souhaitais m'orienter vers l'intelligence artificielle. Cependant, je n'avais pas encore une vision aussi précise du type de problématiques sur lesquelles je souhaitais travailler. Cette année m'a permis de confirmer mon intérêt pour l'intelligence artificielle générative, tout en comprenant que ce qui m'intéresse réellement est de construire des systèmes d'IA complets et utilisables, et pas uniquement de travailler sur un modèle de manière isolée.

Le projet réalisé durant mon alternance correspond particulièrement bien à cette vision. Il ne suffisait pas d'utiliser un LLM pour obtenir une réponse à partir d'un document. Il fallait partir de rapports financiers complexes et non structurés, comprendre où se trouvait l'information, traiter différents formats, retrouver les données pertinentes, reconstruire certains KPIs puis contrôler la cohérence des résultats. Le système développé combine ainsi plusieurs domaines qui m'intéressent : Generative AI, Vision-Language Models, RAG, embeddings, bases vectorielles, raisonnement, traitement de données et software engineering. La partie production m'a également permis de découvrir davantage les problématiques de cloud, de CI/CD, de monitoring et de déploiement. Le passage d'un prototype expérimental vers une architecture réellement déployable a été l'un des aspects les plus intéressants de mon expérience.

Cette alternance m'a également permis d'évaluer ma capacité à travailler sur un sujet pour lequel je ne disposais pas initialement de toutes les connaissances nécessaires. Au début du projet, plusieurs technologies et concepts étaient nouveaux pour moi, notamment certains services AWS, Bedrock, l'environnement de déploiement interne ou encore certaines problématiques propres à l'industrialisation d'une application utilisant des LLM. La principale difficulté n'était donc pas uniquement de résoudre le problème technique, mais d'être capable d'apprendre suffisamment rapidement pour avancer malgré ces inconnues.

J'ai progressivement compris qu'il n'était pas nécessaire de maîtriser toutes les technologies avant de commencer un projet. Une partie importante du travail d'un ingénieur consiste justement à être capable d'identifier ce qu'il ne connaît pas, de rechercher les informations nécessaires, d'expérimenter puis de prendre des décisions en fonction des résultats obtenus. Cette capacité d'apprentissage me semble d'autant plus importante dans le domaine de l'intelligence artificielle générative, où les modèles, les outils et les méthodes évoluent extrêmement rapidement.

J'ai également identifié certaines difficultés auxquelles je devrai continuer à travailler. Il est par exemple facile, lorsqu'on découvre de nouvelles technologies, de vouloir expérimenter plusieurs solutions en parallèle ou de complexifier trop rapidement une architecture. Cette expérience m'a appris à davantage raisonner à partir du besoin réel : définir le problème, établir des critères mesurables, construire une première solution, tester ses limites puis ajouter de la complexité uniquement lorsqu'elle est justifiée. J'ai également progressé dans ma manière de communiquer sur mon travail. Dans un environnement professionnel, une solution techniquement intéressante n'a de valeur que si l'on est capable d'expliquer son fonctionnement, ses résultats, ses limites et les raisons ayant conduit aux différents choix techniques.

À court terme, mon objectif professionnel est donc de poursuivre dans un poste d'ingénieur en intelligence artificielle, avec une spécialisation autour de la Generative AI et des systèmes agentiques. Je souhaite néanmoins conserver une dimension importante de software et data engineering. Je ne souhaite pas limiter mon travail au prompt engineering ou à l'utilisation d'APIs de modèles existants. Ce qui m'intéresse est de comprendre suffisamment les modèles et leur fonctionnement pour pouvoir construire autour d'eux des architectures adaptées : systèmes de retrieval, agents et outils, traitement multimodal, validation,

évaluation, observabilité et déploiement.

Je souhaite également continuer à approfondir les aspects plus fondamentaux des LLM et des modèles multimodaux. Comprendre les mécanismes d'attention, les représentations, les méthodes d'entraînement ou d'adaptation des modèles me semble important pour ne pas considérer les modèles comme de simples boîtes noires. Mon expérience durant l'alternance m'a justement montré que cette compréhension permet de prendre de meilleures décisions lorsque les approches standards atteignent leurs limites.

À moyen terme, je souhaite évoluer vers des responsabilités où je pourrai intervenir sur l'ensemble du cycle de vie d'un système d'intelligence artificielle : compréhension du besoin, conception de l'architecture, expérimentation, développement, évaluation puis mise en production. Je souhaite travailler sur des projets où l'IA répond à un problème concret et où les performances du système peuvent être réellement mesurées. À terme, je souhaite être capable de prendre davantage de responsabilités sur les choix d'architecture et sur la conception technique de systèmes d'IA complexes.

Cette expérience a donc davantage confirmé mon orientation qu'elle ne l'a complètement transformée. Elle m'a permis de passer d'un intérêt général pour l'intelligence artificielle à un projet professionnel beaucoup plus précis autour de la conception et de l'industrialisation de systèmes de Generative AI. Elle m'a surtout montré que cet environnement correspond à ma manière de travailler : comprendre un problème complexe, apprendre rapidement ce qui est nécessaire, expérimenter plusieurs approches puis transformer progressivement une idée en un système fonctionnel et fiable.

Conclusion générale

Cette alternance m'a permis de concevoir et d'industrialiser un système d'intelligence documentaire capable d'exploiter des rapports financiers complexes. Ce qui semblait au départ être un simple problème d'extraction de KPI s'est révélé beaucoup plus large, nécessitant de combiner traitement multimodal, retrieval hybride, raisonnement sur les dépendances, calcul et validation.

Au-delà de la solution développée, cette expérience a surtout fait évoluer ma manière d'aborder un projet d'intelligence artificielle. J'ai compris qu'un système performant ne dépend pas uniquement du modèle utilisé, mais également de son architecture, de la qualité des données, de la robustesse des traitements, de la traçabilité, de l'observabilité et de sa capacité à être réellement déployé en production. Cette alternance confirme ainsi mon intérêt pour la conception de systèmes d'IA avancés, multimodaux et industrialisables.

6. Bibliographie

- [1] Ashish VASWANI et al. « Attention Is All You Need ». In : *Advances in Neural Information Processing Systems*. T. 30. Travail fondateur introduisant l'architecture Transformer et les mécanismes d'attention sur lesquels reposent les LLM mobilisés dans le projet. 2017. URL : <https://papers.neurips.cc/paper/7181-attention-is-all-you-need>.
- [2] Brandon SMOCK, Rohith PESALA et Robin ABRAHAM. « PubTables-1M : Towards Comprehensive Table Extraction From Unstructured Documents ». In : *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Cette publication traite de la détection et de la compréhension de tableaux dans des documents non structurés, en lien direct avec l'utilisation de Table Transformer (TATR) dans le pipeline. 2022, p. 4634-4642. URL : https://openaccess.thecvf.com/content/CVPR2022/html/Smock_PubTables-1M_Towards_Comprehensive_Table_Extraction_From_Unstructured_Documents_CVPR_2022_paper.html.
- [3] Patrick LEWIS et al. « Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks ». In : *Advances in Neural Information Processing Systems*. T. 33. Référence majeure sur le Retrieval-Augmented Generation, principe utilisé dans le projet pour associer recherche d'information et génération par modèle de langage. 2020, p. 9459-9474. URL : <https://proceedings.neurips.cc/paper/2020/hash/6b493230205f780e1bc26945df7481e5-Abstract.html>.
- [4] Nils REIMERS et Iryna GUREVYCH. « Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks ». In : *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*. Ce travail présente des représentations vectorielles adaptées à la comparaison sémantique de textes, proches des mécanismes d'embeddings et de similarité cosinus utilisés pour le retrieval. 2019, p. 3982-3992. URL : <https://aclanthology.org/D19-1410/>.
- [5] Weiwei SUN et al. « Is ChatGPT Good at Search? Investigating Large Language Models as Re-Ranking Agents ». In : *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Cette étude analyse l'utilisation de LLM pour réévaluer et ordonner des résultats de recherche, principe proche du score d'importance utilisé pour classer les fragments du projet. 2023, p. 14918-14937. URL : <https://aclanthology.org/2023.emnlp-main.923/>.

A. Annexes

A. Visualisation des impacts– Diagrammes Butterfly




FIGURE 10 – Impacts liés à l'amélioration du retrieval RAG




FIGURE 11 – Impacts liés à l'architecture multi-agents




FIGURE 12 – Impacts liés à la validation et au mécanisme de fallback




FIGURE 13 – Impacts liés au monitoring et à l'optimisation des ressources




FIGURE 14 – Cycle de vie du service d'intelligence documentaire

B. Pipeline d'ingestion et de préparation des données

Cette première architecture détaille la transformation des rapports financiers PDF en données exploitables par le système de recherche. Les documents sont d'abord stockés dans Amazon S3, puis traités page par page afin de respecter les contraintes imposées aux modèles multimodaux.

Chaque page est analysée par un Vision-Language Model (VLM), qui permet d'extraire simultanément le contenu textuel, les informations visuelles et différents signaux structurés. Ces informations sont ensuite consolidées sous forme de métadonnées au niveau de la page et du document. Enfin, les unités de retrieval sont construites, vectorisées puis indexées dans une base vectorielle avec leurs métadonnées associées. Cette étape constitue l'entrée du système de retrieval hybride présenté dans l'annexe suivante.




FIGURE 15 – Architecture détaillée du pipeline d'ingestion multimodale et d'indexation

C. Système de retrieval hybride symbolique-sémantique

Cette architecture présente le mécanisme développé pour sélectionner les informations pertinentes nécessaires à l'extraction ou à la reconstruction d'un KPI. Contrairement à une recherche vectorielle classique reposant uniquement sur la similarité sémantique, le système prend également en compte la structure et la complémentarité des informations recherchées.

Une représentation symbolique permet notamment d'identifier les correspondances directes, les résultats partiels ainsi que les informations complémentaires devant être recherchées. Une vérification de la période concernée est ensuite effectuée avant de combiner ces signaux avec la similarité issue des embeddings. Le score hybride obtenu permet finalement de sélectionner les chunks les plus pertinents pour chaque KPI.




FIGURE 16 – Architecture détaillée du système de retrieval hybride symbolique-sémantique

D. Génération structurée et reconstruction des KPI

Cette dernière architecture détaille le traitement réalisé après la phase de retrieval. Les informations récupérées sont d'abord transformées en une représentation JSON respectant un schéma prédéfini. Une étape de validation contrôle ensuite la structure produite et déclenche, lorsque nécessaire, une correction déterministe ou une nouvelle génération par le LLM.

Les KPI sont ensuite organisés sous forme de graphe de dépendances permettant de distinguer les valeurs directement disponibles, celles pouvant être calculées et celles nécessitant des informations supplémentaires. Selon le cas rencontré, le système peut conserver une valeur existante, effectuer un calcul déterministe, rechercher des données historiques ou déclencher un retrieval secondaire. Cette séparation entre raisonnement, utilisation d'outils et calcul permet de limiter la dépendance au LLM pour les opérations déterministes et d'améliorer la traçabilité du résultat final.




FIGURE 17 – Architecture détaillée de génération structurée, de résolution des dépendances et de reconstruction des KPI

E. Exemples d'exécution et métriques techniques

Cette annexe présente deux exemples issus de l'exécution du pipeline. Le premier illustre le fonctionnement du système de retrieval et de résolution pour un KPI donné. Le second présente le suivi de la consommation

des modèles et la décomposition du coût selon les différents rôles LLM.

E.1 Exemple d'exécution du retrieval et du solver

La Figure 18 présente un exemple d'exécution pour le KPI *Passenger Revenue*. Elle permet notamment d'observer le filtrage des chunks selon la compagnie et la période, leur classification, leur classement ainsi que leur transmission au mécanisme de résolution.

```

--- Processing airline/period 1: Air Canada - Q1 ---
[1/9] Extracting x1...
[DEBUG-FILTER] entity_name='Air Canada' entity_code='ACA' doc_type='INDIVIDUAL'
[DEBUG-FILTER] known_names for entity: {'aca', 'air canada'}
[DEBUG-FILTER] total chunks in collection: 24
[DEBUG-FILTER] chunk 0: flat_relevant={'airlines_0': 'Air Canada', 'airlines_detected_0': 'Air Canada', 'importance_for_calculation': 9, 'period_0': 'Q1', 'periods_detected_0': 'Q1'}
[DEBUG-FILTER] chunk 0: unflat_relevant={'importance_for_calculation': 9, 'airlines': ['Air Canada'], 'airlines_detected': ['Air Canada'], 'period': ['Q1'], 'periods_detected': ['Q1']}
[DEBUG-FILTER] chunk 1: flat_relevant={'airlines_0': 'Air Canada', 'airlines_detected_0': 'Air Canada', 'importance_for_calculation': 8, 'period_0': 'Q1', 'periods_detected_0': 'Q1'}
[DEBUG-FILTER] chunk 1: unflat_relevant={'importance_for_calculation': 8, 'airlines': ['Air Canada'], 'airlines_detected': ['Air Canada'], 'period': ['Q1'], 'periods_detected': ['Q1']}
[DEBUG-FILTER] chunk 2: flat_relevant={'airlines_0': 'Air Canada', 'airlines_detected_0': 'Air Canada', 'importance_for_calculation': 8, 'period_0': 'Q1', 'periods_detected_0': 'Q1'}
[DEBUG-FILTER] chunk 2: unflat_relevant={'importance_for_calculation': 8, 'airlines': ['Air Canada'], 'airlines_detected': ['Air Canada'], 'period': ['Q1'], 'periods_detected': ['Q1']}
[DEBUG-FILTER] chunk 3: flat_relevant={'airlines_0': 'Air Canada', 'airlines_detected_0': 'Air Canada', 'importance_for_calculation': 6, 'period_0': 'Q1', 'periods_detected_0': 'Q1'}
[DEBUG-FILTER] chunk 3: unflat_relevant={'importance_for_calculation': 6, 'airlines': ['Air Canada'], 'airlines_detected': ['Air Canada'], 'period': ['Q1'], 'periods_detected': ['Q1']}
[DEBUG-FILTER] chunk 4: flat_relevant={'airlines_0': 'Air Canada', 'airlines_detected_0': 'Air Canada', 'importance_for_calculation': 8, 'period_0': 'Q1', 'periods_detected_0': 'Q1'}
[DEBUG-FILTER] chunk 4: unflat_relevant={'importance_for_calculation': 8, 'airlines': ['Air Canada'], 'airlines_detected': ['Air Canada'], 'period': ['Q1'], 'periods_detected': ['Q1']}
[FILTER] 12/24 chunks passed (airline_skip=0, importance<4=12, page_airline_exact=15, page_airline_fuzzy=0, doc_airline_exact=9, doc_airline_fuzzy=0)
[FILTER] first passing chunk: idx=0 page=11 airlines=['Air Canada'] importance=9 airline_scope=PAGE-EXACT

[SOLVER] KPI = 'passenger revenue'
[SOLVER] Spec: type=différance, vars=['passenger revenue', 'traffic revenue', 'total revenue', 'cargo revenue', 'mail revenue', 'other revenue']
[SOLVER] Signature T = [0, 1, 1, -1, -1, -1]
[SOLVER] Required: +idx={1, 2}, -idx={3, 4, 5}
[SOLVER] Classification (passenger revenue): T1-DIRECT=4 T2-PAIRED=0 T3-BACKUP=1 T4-LAST=7
T1 chunk 0 Lk=[0, None, None, None, None, None]
T1 chunk 1 Lk=[0, None, None, -1, None, None]
T1 chunk 22 Lk=[0, None, None, None, None, None]
T1 chunk 23 Lk=[0, None, None, -1, None, -1]

[RANKING] Top 5 of 12 for 'passenger revenue' (period=Q1):
#1 chunk= 0 B0 T1-DIRECT A-PAGE-EXACT P1-EXACT score= 17.08 imp= 9.0 cos= 8.08 periods=['Q1']
#2 chunk= 22 B0 T1-DIRECT A-PAGE-EXACT P1-EXACT score= 16.73 imp= 9.0 cos= 7.73 periods=['Q1']
#3 chunk= 23 B0 T1-DIRECT A-PAGE-EXACT P1-EXACT score= 16.44 imp= 9.0 cos= 7.44 periods=['Q1']
#4 chunk= 1 B0 T1-DIRECT A-PAGE-EXACT P1-EXACT score= 16.41 imp= 8.0 cos= 8.41 periods=['Q1']
#5 chunk= 2 B0 T3-BACKUP A-PAGE-EXACT P1-EXACT score= 16.01 imp= 8.0 cos= 8.01 periods=['Q1']
... (lowest) chunk= 12 B0 T4-LAST A-PAGE-EXACT P2-SHARED score= 15.20
[2/9] Extracting x2...

```

FIGURE 18 – Exemple d'exécution du retrieval hybride et du solver

E.2 Suivi du coût et de la consommation des modèles

Le pipeline collecte également des métriques relatives aux appels aux modèles. La Figure 19 présente un exemple de décomposition du nombre d'appels, des tokens consommés et du coût associé aux différents rôles intervenant dans le traitement.

COST PER LLM ROLE					
Role	Calls	Input	Output	Embed	Cost
builder	9	27,306	2,539	0 \$	0.1200
embedder	33	0	0	23,522 \$	0.0024
extractor	58	202,063	32,115	0 \$	1.0879
fetcher	9	23,854	81	0 \$	0.0728
planner	9	23,280	1,284	0 \$	0.0891
validator	9	5,008	2,147	0 \$	0.0472
TOTAL	127	281,511	38,166	23,522 \$	1.4194

FIGURE 19 – Exemple de suivi de la consommation de tokens et du coût par rôle LLM

Ces informations permettent d'identifier les composants les plus coûteux du pipeline et constituent une base pour l'optimisation du nombre d'appels, du contexte transmis et du choix des modèles.

Résumé

Cette alternance réalisée chez Amadeus porte sur la conception et l'industrialisation d'un système d'intelligence documentaire destiné à automatiser l'exploitation de rapports financiers de compagnies aériennes. L'objectif est de transformer des PDF hétérogènes contenant texte, tableaux et graphiques en KPI structurés, fiables et traçables.

La solution combine ingestion multimodale, Vision-Language Models, Retrieval-Augmented Generation, embeddings et retrieval hybride. Lorsque certains KPI ne sont pas directement présents, une représentation symbolique et un graphe de dépendances permettent d'identifier les informations nécessaires et de reconstruire les valeurs à l'aide de calculs déterministes.

Le système a ensuite été industrialisé et évalué sur des données historiques. Les résultats obtenus atteignent un taux d'exactitude compris entre 99,08 % et 100 %, avec un temps de traitement de quelques minutes par période.

Mots-clés : Intelligence documentaire, IA générative, LLM, RAG, VLM, retrieval hybride, KPI financiers.

Abstract

This apprenticeship at Amadeus focuses on the design and industrialization of an intelligent document processing system for airline financial reports. The objective is to transform heterogeneous PDF documents containing text, tables and charts into structured, reliable and traceable KPIs.

The solution combines multimodal ingestion, Vision-Language Models, Retrieval-Augmented Generation, embeddings and hybrid retrieval. When some KPIs are not explicitly available, a symbolic representation and a dependency graph are used to identify the required information and reconstruct the values through deterministic computations.

The system was then industrialized and evaluated on historical data. The experiments achieved an accuracy ranging from 99.08 % to 100 %, with processing times of only a few minutes per reporting period.

Keywords : Intelligent Document Processing, Generative AI, LLM, RAG, VLM, Hybrid Retrieval, Financial KPIs.