Probabilité et Statistiques

L2 Info

Anna Melnykova

Laboratoire de Mathématiques d'Avignon
anna.melnykova@univ-avignon.fr

2024-2025

Organisation

Responsable :

- **Nom :** Anna Melnykova, MCF, Laboratoire de Mathématiques
- **Q& A :** anna.melnykova@univ-avignon.fr
- **Télécharger ces transparents :** en ligne

Cours :

- 3 CM $\times$ 3h, 5 TD $\times$ 3h, 4 TP $\times$ 3h
- 2 CC écrits + 1 TP noté !

Acknowledgement : *ce support utilise partiellement les polycopiés/transparents d'Olivier François et d'Hervé Guiol (Grenoble INP). Le modèle de présentation est fourni par Vincent Labatut (Université Avignon).*

Plan du cours

1. Introduction. Variables discrètes.
2. Variables continues : densité, l'espérance, variance, lois usuelles.
3. Loi de grands nombres, théorème centrale limite.
4. Statistique : Intervalles de confiance
5. Tests statistiques

Chapitre 1

Introduction. Variables discrètes.

AVIGNON UNIVERSITÉ

Vocabulaire probabiliste

1. **Expérience aléatoire (ou épreuve) :** une expérience dont on ne peut pas prévoir le résultat, et qui, renouvelée dans des conditions identiques, ne donne pas forcément le même résultat à chaque renouvellement.
2. **Issue (ou éventualité) :** Chacun des résultats possibles de l'expérience.
3. **Espace Fondamental Ω :** un ensemble, regroupant l'ensemble des issues.
4. **Événement :** un ensemble d'issues correspondants à différents résultats possibles de l'expérience aléatoire. Chaque événement fait donc une partie de Ω.
5. **Tribu $\mathcal{P}(\Omega)$:** un ensemble de *tout* événements.

Expérience aléatoire : exemples

Exemple : lancer d'une piéce

1. **Expérience aléatoire (ou épreuve) :** lancer d'une piéce
2. **Issues (ou éventualités) :**
   - Pile (0)
   - Face (1)
3. **Espace Fondamental :** $\Omega = \{0, 1\}$
4. **Evenements :**
   - obtenir pile : $\{0\}$
   - obtenir face : $\{1\}$
   - obtenir ni pile, ni face : $\emptyset$
   - obtenir soit pile, soit face : Ω
5. **Tribu** $\mathcal{P}(\Omega)$ **:** $\{\emptyset, \{0\}, \{1\}, \Omega\}$

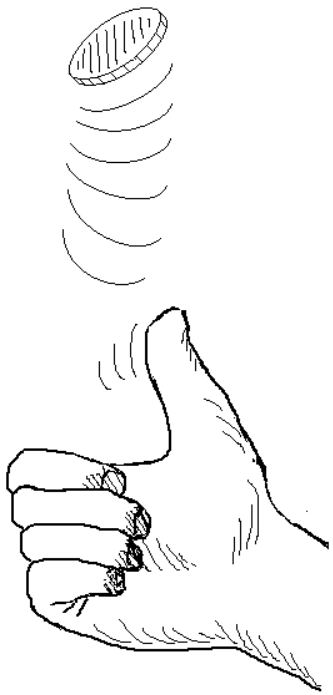

Opérations sur les événements

- **L'union** d'événements est un événement
- **L'intersection** d'événements est un événement
- **Le complémentaire d'un événement** est un événement
- *En conséquence*, $\emptyset$ et Ω sont des événements !

Exemple : lancer d'un dé

- Considérons $A = \{1, 2, 3\}$ et $B = \{2, 4, 6\}$. $A, B \in \mathcal{P}(\Omega)$
- $A \cup B = \{1, 2, 3, 4, 6\} \in \mathcal{P}(\Omega)$
- $A \cap B = \{2\} \in \mathcal{P}(\Omega)$
- $\bar{A} \equiv A^c = \Omega \setminus A = \{4, 5, 6\} \in \mathcal{P}(\Omega)$

Mesure de Probabilité : definition intuitive

- **La probabilité $\mathbb{P}$ d'un événement** est un nombre réel compris entre 0 et 1.
- Plus ce nombre est grand, plus *le risque*, ou *la chance*, que l'événement se produise est grand.
- La probabilité est naturellement liée à **fréquence d'apparition** d'un évènement dans la vie réelle.

Exemple : lancer d'une piéce

Question : comment calculer la probabilité ***p*** d'obtenir face (nous ne savons pas si la pièce est bien équilibré) ?

Mesure de Probabilité : definition intuitive

- **La probabilité $\mathbb{P}$ d'un événement** est un nombre réel compris entre 0 et 1.
- Plus ce nombre est grand, plus *le risque*, ou *la chance*, que l'événement se produise est grand.
- La probabilité est naturellement liée à **fréquence d'apparition** d'un évènement dans la vie réelle.

Exemple : lancer d'une piéce

Question : comment calculer la probabilité ***p*** d'obtenir face (nous ne savons pas si la pièce est bien équilibré) ?
Réponse : lancer la pièce une infinité des fois !

$$p = \lim_{n \to \infty} \frac{n_p}{n},$$

ou n - nombre d'expérience totale, n_p - nombre de cas ou on a eu face.

Mesure de Probabilité : formalisation

Définition 1.1

Une mesure de probabilité sur $(\Omega, \mathcal{P}(\Omega))$, notée $\mathbb{P}$ est une fonction de $\mathcal{P}(\Omega) \to [0,1]$ vérifiant

- $\mathbb{P}(\Omega) = 1$;
- Pour toute suite $A_i \in \mathcal{P}(\Omega),\ i \geq 1$ d'événements disjoints ($A_i \cap A_j = \emptyset$ si $i \neq j$), on a

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i)$$

Mesure de Probabilité : formalisation

- $\mathbb{P}(\emptyset) = 0$
- Si $A \in \mathcal{P}(\Omega)$ alors $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$
- Si $A, B \in \mathcal{P}(\Omega)$, alors $\mathbb{P}\left(A \cup B\right) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$
- Si $A, B \in \mathcal{P}(\Omega)$, alors $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$ si et seulement si A et B sont indépendants

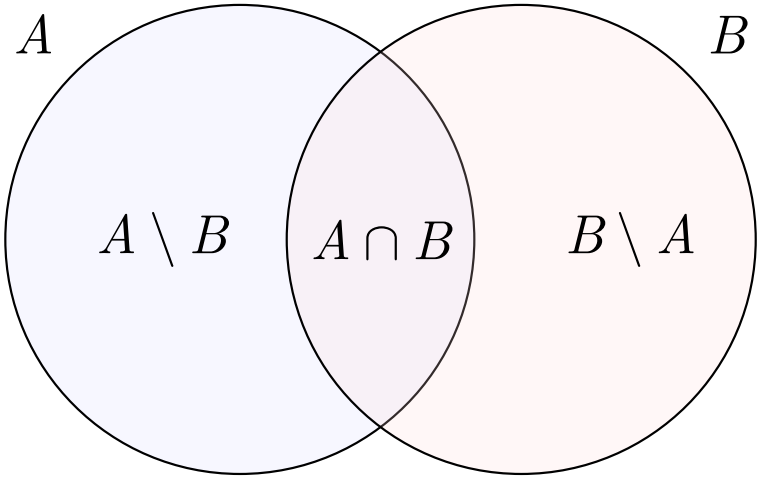

- Pour toute suite d'événements croissants $A_1 \subset A_2 \ldots$, on a

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \lim_{n \to \infty} \mathbb{P}\left(A_n\right)$$

Exemples du calcul : Squid Game

Exemple du calcul : Squid Game

Dans la Saison 2 de "Le Jeu du Calamar", Gi-Hun confronte le Recruteur dans la roulette russe. Ils mettent une balle dans la barrette d'un révolver (qui peut en contenir 6) et commencent à jouer jusqu'à que quelqu'un se tue. C'est Gi-Hun qui joue le premier tour.

1. Quelle est la probabilité qu'ils jouent au moins 2 tours ?
2. Quelle est la probabilité que le Recruteur se tue à 4ème tour ?
3. Quelle est la probabilité que c'est le Recruteur qui se tue ?

Exemples du calcul : Squid Game

1. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$:

$$\mathbb{P}\,(\text{jouer au moins 2 tours}) = 1 - \mathbb{P}\,(\text{jouer seulement 1 tour})$$

2. Recruteur peut se tuer à 4ème tour si et seulement si il est toujours en vie, et Gi-Hun aussi. Alors, la probabilité de l'évènement est calculée comme suite :

$$\mathbb{P}\,(\text{Recruteur se tue à 4ème tour}) = \mathbb{P}\,(\text{1 tour : Gi-Hun est en vie}) \cdot \mathbb{P}\,(\text{2 tour : R est en vie}) \cdot \mathbb{P}\,(\text{3 tour : R est en vie}) \cdot \mathbb{P}\,(\text{4 tour : R se tue}) = \frac{5}{6} \cdot \frac{4}{5} \cdot \frac{3}{4} \cdot \frac{1}{3} = \frac{1}{6}$$

Exemples du calcul : Squid Game

3 Il ne nous reste que calculer la probabilité que c'est le Recruteur qui se tue. Il joue le 2, 4 et 6 tour. Alors, on peut calculer la proba de cet évènement comme la somme de probabilités de 3 évènements :

$$\mathbb{P}\left(\text{Recruteur se tue}\right) =$$
$$\mathbb{P}\left(\text{R se tue à 2 T, } \textbf{OU} \text{ R se tue à 4 T, } \textbf{OU} \text{ R se tue à 6 T}\right) =$$
$$\mathbb{P}\left(\text{R se tue à 2 T}\right) + \mathbb{P}\left(\text{R se tue à 4 T}\right) + \mathbb{P}\left(\text{ R se tue à 6 T}\right)$$

Exercice : Finir. Est-ce que la probabilité de mourir est plus grande pour Gi-Hun (vu qu'il commence en premier) ?

Probabilités conditionnelles. Indépendance.

Formule de Bayes

Soient $A \in \mathcal{F}$ et $B \in \mathcal{F}$ deux événements tels que $\mathbb{P}(B) > 0$. On appelle **probabilité conditionnelle** de A sachant B la grandeur

$$\mathbb{P}(A|B) = \frac{\mathbb{P}(A \cap B)}{P(B)}$$

Indépendance

Si $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$, les événements A et B sont dits **indépendants**.

Probabilités conditionnelles. Exemple.

Exemple : lancer d'un dé

Quelqu'un a lancé un dé (équilibré), et il nous a informés que le valeur sur face est pair. Comment calculer la probabilité que la valeur sur face est inférieure de 4 ?

Probabilités conditionnelles. Exemple.

Exemple : lancer d'un dé

Quelqu'un a lancé un dé (équilibré), et il nous a informés que le valeur sur face est pair. Comment calculer la probabilité que la valeur sur face est inférieure de 4 ?

- Considérons $A = \{1, 2, 3\}$ et $B = \{2, 4, 6\}$. Notons que $\mathbb{P}(B) = \frac{1}{2}$
- $\mathbb{P}(A \cap B) = \mathbb{P}(\{2\}) = \frac{1}{6}$
- Par la formule de Bayes

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{1}{6}}{\frac{1}{2}} = \frac{1}{3}$$

Probabilités conditionnelles. Propriétés.

Soient $B_1, B_2, \ldots$ une suite d'événements mutuellement exclusifs ($B_i \cap B_j = \emptyset \quad \forall i \neq j$) tels que $\forall n \geq 1,\ \mathbb{P}(B_n) \neq 0$ et $\bigcup_{n\geq 1} B_n = \Omega$. Alors :

- **Formule des probabilités totales** :

$$\forall A \in \mathcal{F},\ \mathbb{P}(A) = \sum_{n\geq 1} \mathbb{P}(A|B_n)\mathbb{P}(B_n)$$

- **Formule de Bayes** :

$$\mathbb{P}(B_i|A) = \frac{\mathbb{P}(A \cap B_i)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|B_i)\mathbb{P}(B_i)}{\sum_{n\geq 1} \mathbb{P}(A|B_n)\mathbb{P}(B_n)}$$

Comment caractériser une probabilité $\mathbb{P}$?

- Ω **est dénombrable (ou fini) :** on peut tout simplement définir la probabilité pour chaque issue dans Ω, qu'on appellerai **la fonction de masse.** *(Voir exemple avec le lancer de dé).*
- Ω **est non dénombrable (par exemple, $X \in \mathbb{R}$) :** on définit une mesure de probabilité sur $\mathcal{P}(\Omega)$ à l'aide d'une fonction $F : \mathcal{P}(\Omega) \to [0, 1]$ telle que $F(x) = \mathbb{P}(] - \infty, x])$, qui s'appelle **fonction de répartition**.

Comment calculer la probabilité d'un évènement ?

- Dans le cas **dénombrable** :

$$\mathbb{P}(A) = \frac{\text{nombre de modalités qui correspondent à } A}{\text{nombre de modalités dans } \Omega}$$

- Cas **non dénombrable** :

$$\mathbb{P}(A) = \frac{\text{Volume de } A}{\text{Volume de } \Omega}$$

Variable aléatoire discrète

Définition 1.2

Une variable aléatoire $X : \Omega \to \mathbb{R}$ est dite **discrète** s'il existe un ensemble fini ou infini dénombrable $E \in \mathbb{R}$ tel que $\mathbb{P}(X \in E) = 1$.

Exemples :

- Pile ou face (lancer d'une pièce)
- Face d'un dé
- Somme de faces de N dés

Fonction de répartition

Définition 1.3

Soit X une variable aléatoire sur $(\Omega, \mathcal{P}(\Omega), \mathbb{P})$. On note F_X la fonction de $\mathbb{R} \to [0,1]$ définie $\forall x \in \mathbb{R}$ par $F_X := \mathbb{P}(X \leq x)$. La fonction F est appelée **fonction de répartition** de la variable aléatoire X.

Définition 1.4

Soit X une variable aléatoire de fonction de répartition F_X. **Le quantile** q_p **(d'ordre** $p \in [0,1]$) de X est solution de $F_X(q_p) = p$, i.e.

$$q_p = F_X^{-1}(p).$$

Fonction de répartition : propriétés

1. F_x est croissante au sens large : $\forall (x, y) \in \mathbb{R}^2$,

$$x < y \Rightarrow F_X(x) \leq F_X(y)$$

2. $\lim_{x \to -\infty} F_X(x) = 0 \quad \lim_{x \to +\infty} F_X(x) = 1$
3. F_x est continue à droite :

$$\forall x \in \mathbb{R} : \lim_{h \to 0} F_X(x + h) = F_X(x)$$

4. $\lim_{h \to 0} F_X(x - h) = \mathbb{P}(X < x) \leq F_X(x)$

Exemple : lancer d'une pièce

- $X = \mathbb{1}_{\text{la pièce a tombé sur face}}$
- $\Omega = \{0, 1\}$
- $\mathcal{F} : \{\emptyset, \{0\}, \{1\}, \Omega\}$
- $\mathbb{P}(X = 0) = \mathbb{P}(X = 1) = \frac{1}{2}$
- $F_X(x) = \begin{cases} 0 & \text{si } x < 0, \\ \frac{1}{2} & \text{si } 0 \leq x < 1, \\ 1 & \text{si } x \geq 1 \end{cases}$

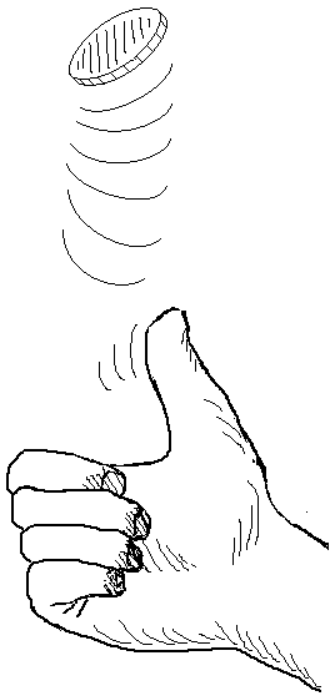

Exercice : faire un graphique !

Exemple : lancer d'un dé

- $X =$ nombre sur face d'un dé
- $\Omega = \{1, 2, 3, 4, 5, 6\}$
- $\mathbb{P}(X = k) = \frac{1}{6}$
- $F_X(x) = \begin{cases} 0 & \text{si } x < 1, \\ \frac{k}{6} & \text{si } k \leq x < k+1, \ \forall k \in \{1, \ldots, 5\} \end{cases}$

Exercice : faire un graphique !

Fonction de masse

Définition 1.5

Soit X une variable aléatoire discrète à valeurs dans un ensemble $E = \{e_1, e_2, \dots\}$ et F_X sa fonction de répartition. On appelle **fonction de masse de** X, la fonction $p_X : E \to [0,1]$ définie par

$$p_X(e_i) := \mathbb{P}(X = e_i) = F_X(e_i) - F_X(e_{i-1}),$$

avec la convention $F_X(e_0) = 0$.

Remarque

Notons que

$$F_X(x) = \sum_{k=1}^{i} p_X(e_k), \quad \forall x \in [e_i, e_{i+1}).$$

Espérance mathématique

Définition 1.6

Soit X une variable aléatoire discrète à valeurs dans un ensemble $E = \{e_1, e_2, \dots\}$ et p_X sa fonction de masse. **L'espérance mathématique** de X (appelé aussi moment d'ordre 1) est définie comme

$$\mathbb{E}[X] = \sum_{e_i \in E} e_i p_X(e_i)$$

Exercices

Calculer l'espérance mathématique d'une variable X, ou

1. $X = \mathbb{1}_{\text{la pièce tombe sur pile}}$
2. $X = \{\text{nombre sur face d'un dé equilibré}\}$

Espérance mathématique : propriétés

- $\forall a, b \in \mathbb{R}$ et pour les variables aléatoires X et Y

$$\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

- **Théorème de transfert :** Soit X une v. a. discrète à valeurs dans un ensemble $E = \{e_1, e_2, \dots\}$ et p_X sa fonction de masse. La fonction $g : E \to \mathbb{R}$ est une v. a. discrète et son espérance vaut

$$\mathbb{E}[g(X)] = \sum_{e_i \in E} g(e_i) p_X(e_i).$$

Exemple

Soit X une variable aléatoire discrète à valeurs dans un ensemble $E = \{e_1, e_2, \dots\}$ et p_X sa fonction de masse. Considérons $Y = X^2$.

$$\mathbb{E}[Y] = \mathbb{E}[X^2] = \sum_{e_i \in E} e_i^2 p_X(e_i).$$

Variance

Définition 1.7

La variance d'une variable aléatoire X est définie comme la moyenne des carrés des écarts à la moyenne de X :

$$Var[X] = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right]$$

1. $\forall c \in \mathbb{R} \quad \mathbb{E}[(X-c)^2] \geq Var[X]$
2. $Var[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$ (**Exercice :** prouver !)
3. $Var[aX+b] = Var[aX] = a^2\, Var[X]$ (**Exercice :** prouver !)

Variance : propriétés

- Soient X, Y deux variables aléatoires. On a

$$Var[X+Y] = Var[X] + Var[Y] + 2Cov[X, Y], \text{ ou}$$
$$Cov[X, Y] = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Si X et Y sont indépendantes, $Cov[X, Y] = 0$!

- Soient $X_1, \ldots, X_n$ n variables aléatoires. On a

$$Var\left(\sum_{k=1}^{n} X_k\right) = \sum_{k=1}^{n} Var(X_k) + \sum_{k \neq l} Cov(X_k, X_l)$$

Loi uniforme discrète

Une v. a. X qui prend une valeur dans un ensemble fini de n valeurs possibles suit une loi uniforme lorsque la probabilité que X prenne n'importe quelle valeur dans cet ensemble est égale à $\frac{1}{n}$.

- $\Omega = \{1, \ldots, n\}$
- **Fonction de masse :** $P(X = k) = \frac{1}{n}$
- **Espérance :** $\mathbb{E}[X] = \frac{n+1}{2}$
- **Variance :** $Var[X] = \frac{n^2-1}{12}$

Loi Bernoulli

On considère une variable aléatoire discrète X qui prend la valeur 1 avec la probabilité p, et 0 avec la probabilité $1-p$.

- $\Omega = \{0, 1\}$
- **Fonction de masse :** $P(X = x) = p^x(1-p)^{1-x},\ x \in \{0, 1\}$
- **Espérance :** $\mathbb{E}[X] = 0(1-p) + 1p = p$
- **Variance :**
  $Var[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = [0(1-p) + 1p] - p^2 = p - p^2 = p(1-p)$

Exemples : toutes sortes d'expériences avec deux issues possibles

Loi Binomiale

Considérons n épreuves identiques et indépendantes de Bernoulli. La variable $X \sim B(n, p)$ qui correspond au nombre de fois où un événement de probabilité p se produit au cours de cette suite d'épreuves suit **la loi Binomiale**.

- $\Omega = \{1, \ldots, n\}$
- **Fonction de masse :** $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$
- **Espérance :** $\mathbb{E}[X] = np$
- **Variance :** $Var[X] = np(1-p)$

Loi géométrique

Une variable aléatoire X de loi géométrique $\mathcal{G}(p)$ correspond au rang de la première occurrence d'un événement de probabilité p dans une suite d'épreuves identiques et indépendantes de Bernoulli.

- $\Omega = \mathbb{N}^+$
- **Fonction de masse :** $P(X = k) = (1-p)^{k-1}p$
- **Espérance :** $\mathbb{E}[X] = \frac{1}{p}$
- **Variance :** $Var[X] = \frac{1-p}{p^2}$

Loi de Poisson

Si le nombre moyen d'occurrences dans un intervalle de temps fixé est λ, alors la probabilité qu'il existe exactement k occurrences est donné par la fonction de masse de la loi de Poisson.

- $\Omega = \{1, \ldots, n\}$
- **Fonction de masse :** $P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$
- **Espérance :** $\mathbb{E}[X] = \lambda$
- **Variance :** $Var[X] = \lambda$

Comment simuler les variables discrètes dans R ?

- **Loi Bernoulli :** `rbinom(N,1,p)`
- **Loi Binomiale :** `rbinom(N,n,p)`
- **Loi géométrique :** `rgeom(N,n)`
- **Loi uniforme discrète :** `sample(1:n,N,replace = TRUE)`
- **Loi de Poisson :** `rpois(N,lambda)`,

où N – taille d'échantillon

Chapitre 2

Variables continues : densité, l'espérance, variance, lois usuelles.

AVIGNON UNIVERSITÉ

Variable aléatoire continue

Définition 2.1

Une fonction $X : \Omega \to \mathbb{R}$ c'est **une variable aléatoire continue** s'il existe une fonction $f_X : \mathbb{R} \to [0, 1]$ continue par morceaux vérifiant la propriété

$$\forall a < b, \quad \mathbb{P}\left(X \in [a, b]\right) = \int_a^b f_X(y)\, dy.$$

Cette fonction f_X est appelée **densité de probabilité** de la variable aléatoire X.

La densité de probabilité de la variable continue peut être vue comme l'analogue de la fonction de masse pour les variables discrètes.

Densité de probabilité d'une v. a. continue

Soit X une variable aléatoire continue à valeurs dans $\mathbb{R}$ et F_X sa fonction de répartition.

Définition 2.2

La densité de probabilité de X, qu'on note f_X, c'est la fonction qui satisfait les conditions suivantes $\forall x \in \mathbb{R}$:

- $F_X(x) = \mathbb{P}(X \leq x) = \int_{-\infty}^{x} f_X(y)\,dy$
- $f_X(x) \geq 0$,
- $\int_{-\infty}^{\infty} f_X(x)\,dx = 1$

La densité de probabilité caractérise la loi d'une variable aléatoire continue.

Densité de probabilité d'une v. a. continue

Les propriétés de la densité :

- Si X est une variable aléatoire à densité, alors sa fonction de répartition $F_X(x)$ est continue et dérivable presque partout sur $\mathbb{R}$ et sa dérivée $F'_X(x)$ est (presque partout) égale à la densité de probabilité : $F'_X(x) = f_X(x)$
- $\mathbb{P}(a \leq X \leq b) = \mathbb{P}(a < X \leq b) = \mathbb{P}(a \leq X < b) = \mathbb{P}(a < X < b) = \int_a^b f_X(x)\,dx$
- $\mathbb{P}(X \leq b) = \int_{-\infty}^b f_X(x)\,dx \quad \mathbb{P}(X \geq a) = \int_a^\infty f_X(x)\,dx$

Remarque

"Presque partout" indique que la densité peut avoir une infinité des points ou elle n'est pas défini. Par exemple, elle peut être définie $\forall x \in \mathbb{R}/\mathbb{Q}$. Cela nous ne dérange pas car $\mathbb{P}(x \in \mathbb{Q}) = 0$ (l'ensemble des rationnelles est dénombrable) :

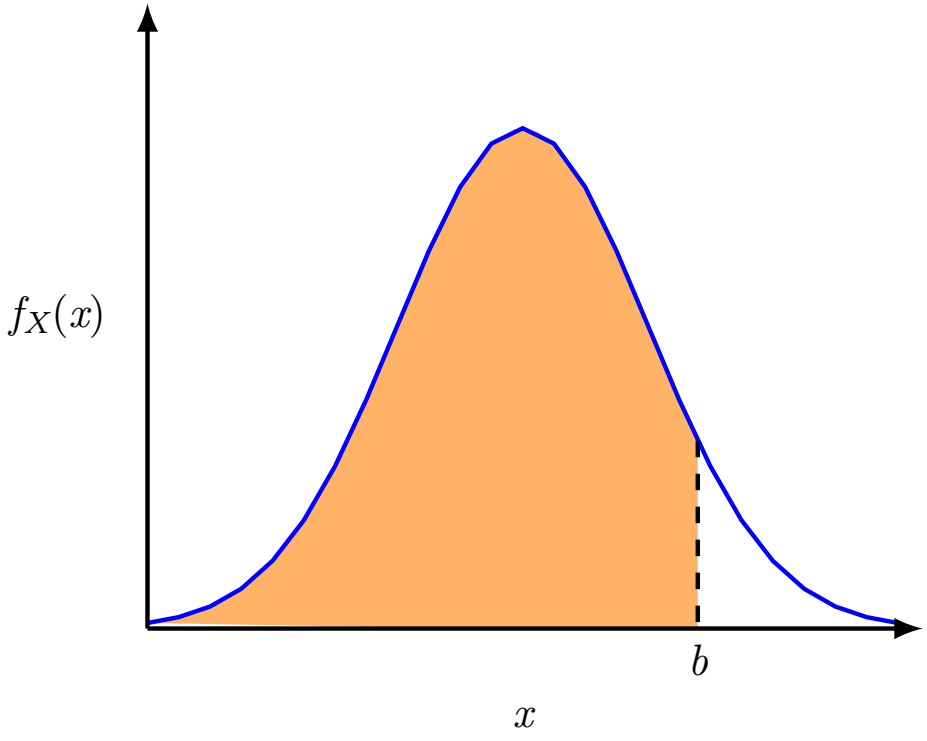

Figure 1 – $\mathbb{P}(X \leq b)$

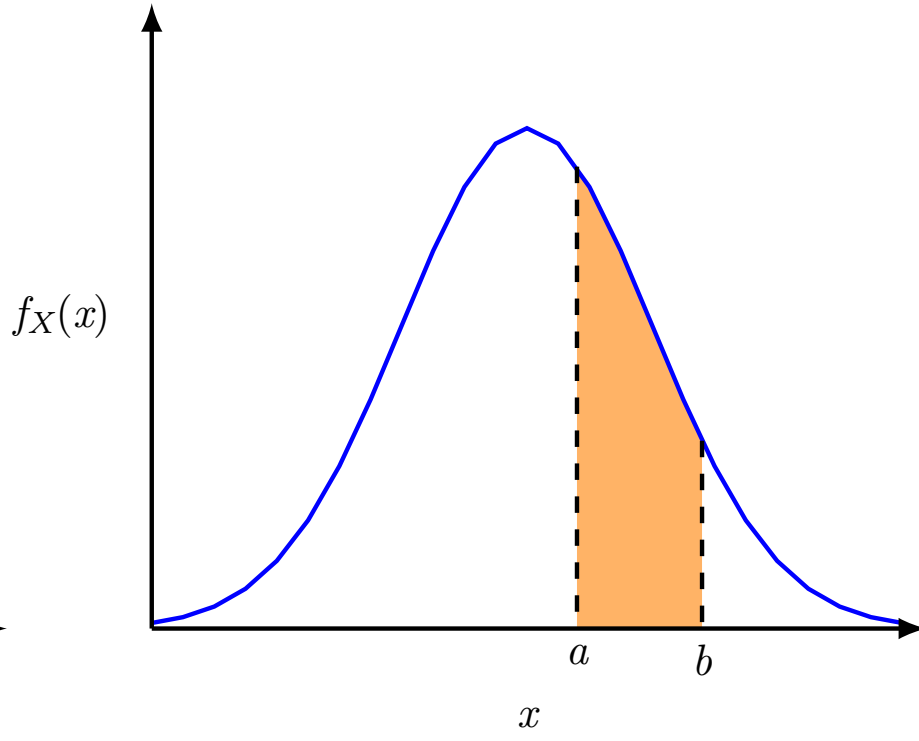

Figure 2 – $\mathbb{P}(a < X \leq b)$

L'espérance d'une v. a. continue

Définition 2.3

L'espérance (ou la moyenne, ou le moment d'ordre 1) d'une variable aléatoire X à valeurs dans $\mathbb{R}$, de fonction de densité de probabilité f_X, et définie comme

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x f_X(x)\, dx$$

Remarque : notons que cette définition correspond à la définition d'espérance pour les variables discrètes, si on remplace l'intégral par la somme et la densité par la masse.

L'espérance d'une v. a. continue : propriétés

- L'espérance est un opérateur linéaire. Soient X et Y deux variables aléatoires

$$\forall a, b \in \mathbb{R} \quad \mathbb{E}\left[aX + bY\right] = a\mathbb{E}[X] + b\mathbb{E}[Y]$$

- **Théorème de transfert**. Soient X une v.a. de densité de probabilité f_X, et $g : \Omega \to \mathbb{R}$ une fonction continue. Si $\int_{-\infty}^{\infty} |g(x)| f_X(x)\, dx$ converge, alors $g(X)$ est une variable aléatoire continue dont l'espérance vaut

$$\mathbb{E}\left[g(X)\right] = \int_{-\infty}^{\infty} g(x) f_X(x)\, dx$$

Par exemple, pour $g(X) = X^2$ on a

$$\mathbb{E}\left[g(X)\right] = \int_{-\infty}^{\infty} x^2 f_X(x)\, dx$$

Variance

Définition 2.4

La variance d'une variable aléatoire X est définie comme la moyenne des carrés des écarts à la moyenne de X :

$$Var[X] = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right]$$

1. $\forall c \in \mathbb{R} \quad \mathbb{E}[(X - c)^2] \geq Var[X]$
2. $Var[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$
3. $Var[aX + b] = Var[aX] = a^2\, Var[X]$

Toutes les définitions et propriétés de la variance sont identiques au cas discret !

Propriétés de la variance et de l'espérance

Soient $X_1, \ldots, X_n$, n variables aléatoires (*même pas indépendantes*). On a

$$\mathbb{E}\left[\sum_{i=1}^{n} X_i\right] = \sum_{i=1}^{n} \mathbb{E}\left[X_i\right]$$

$$Var\left(\sum_{k=1}^{n} X_k\right) = \sum_{k=1}^{n} Var(X_k) + \sum_{k \neq l} Cov(X_k, X_l),$$

ou $Cov[X, Y] = \mathbb{E}\left[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])\right]$.

- En général, $\mathbb{E}[XY] \neq \mathbb{E}[X]\,\mathbb{E}[Y]$!
- C'est possible que $Cov[X, Y] = 0$, mais X et Y ne sont pas indépendants :
  - Posons $Y = X^2$, ou $X \sim \mathcal{N}(0, 1)$, alors $\mathbb{E}[X] = 0$. C'est évident que les 2 variables sont dépendant ! Par contre, pour $Cov[X, Y]$ on a

$$Cov[X, Y] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = \mathbb{E}[X^3] - 0 \cdot \mathbb{E}[X^2] = 0$$

- Par contre, **si X et Y sont indépendantes**, alors $\mathbb{E}[XY] \neq \mathbb{E}[X]\,\mathbb{E}[Y]$, et $Cov[X, Y] = 0$

Degré d'indépendance des distributions

Covariance :

$$\begin{aligned} Cov(X, Y) &= \mathbb{E}\left[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])\right] \\ &= \mathbb{E}\left[XY\right] - \mathbb{E}\left[X\right]\mathbb{E}\left[Y\right] \end{aligned}$$

Coefficient de corrélation :

$$r(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}.$$

Propriétés

- **Symétrie :**

$$Cov(X, Y) = Cov(Y, X), \quad r(X, Y) = r(Y, X)$$

- **Invariance par translations :**

$$Cov(X + a, Y + b) = Cov(X, Y)$$

- **Changement d'échelle :** $Cov(aX, bY) = abCov(X, Y)$ et $r(aX, bY) = \pm r(X, Y)$ où $\pm$ est le signe de ab.

On a aussi :

$$|r(X, Y)| \leq 1$$

Covariance et indépendance

Propriétés

- Si X et Y sont indépendants, alors $Cov(X, Y) = r(X, Y) = 0$.
- Si X et Y sont linéairement reliés ($Y = aX + b$) alors $r(X, Y) = \pm 1$.

Les réciproques sont fausses. **Exemple :** $X = -1, 0, 1$ avec probabilité $1/3$ pour chaque modalité et $Y = X^2$ (montrer).

Autres paramètres de la loi probabiliste

- **Mode :** "la valeur le plus probable", i.e.

$$\arg\max_x f(x)$$

- **Médiane :** la valeur x_m telle que avec la probabilité $\mathbb{P}(X \leq x) = 0.5$, i.e.

$$F_X(x_m) = 0.5$$

- **Fonction de quantiles :** $F_X^{-1}(q)$, qui donne la valeur x telle que avec la proba q, $\mathbb{P}(X \leq x) = q$. Notons que $F_X^{-1}(0.5)$ c'est la médiane !

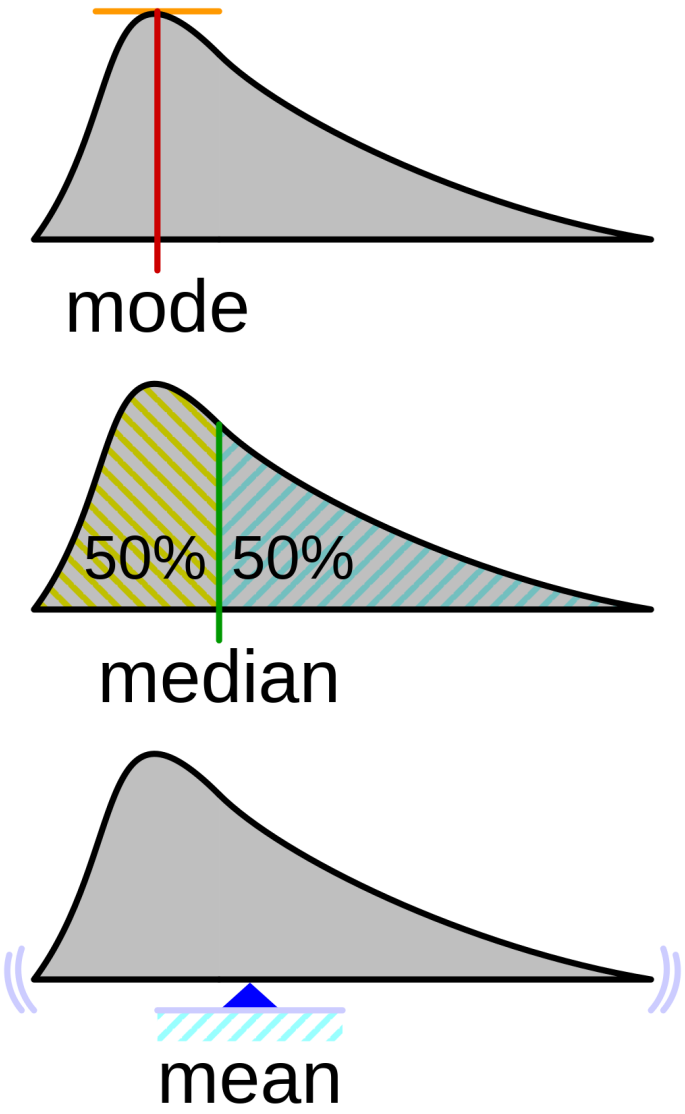
mode
50%
50%
median
mean

Loi uniforme continue

Pour la loi uniforme continue $X \sim \mathcal{U}_{[a,b]}$, la probabilité que X soit dans un intervalle $[a_1, b_1] \in [a, b]$ est égale à la probabilité que X soit dans n'importe quel autre intervalle $[a_2, b_2] \in [a, b]$ si $b_1 - a_1 = b_2 - a_2$. Si $X \sim \mathcal{U}_{[a,b]}$

- $f_X(x) = \frac{1}{b-a} \mathbb{1}_{x \in [a,b]}$
- $F_X(x) = \frac{x-a}{b-a} \mathbb{1}_{x \in [a,b]}$
- $\mathbb{E}[X] = \frac{a+b}{2}$
- $Var[X] = \frac{(b-a)^2}{12}$
- Mode : n'importe quelle valeur dans (a, b)
- Médiane : $\frac{a+b}{2}$

Loi uniforme continue

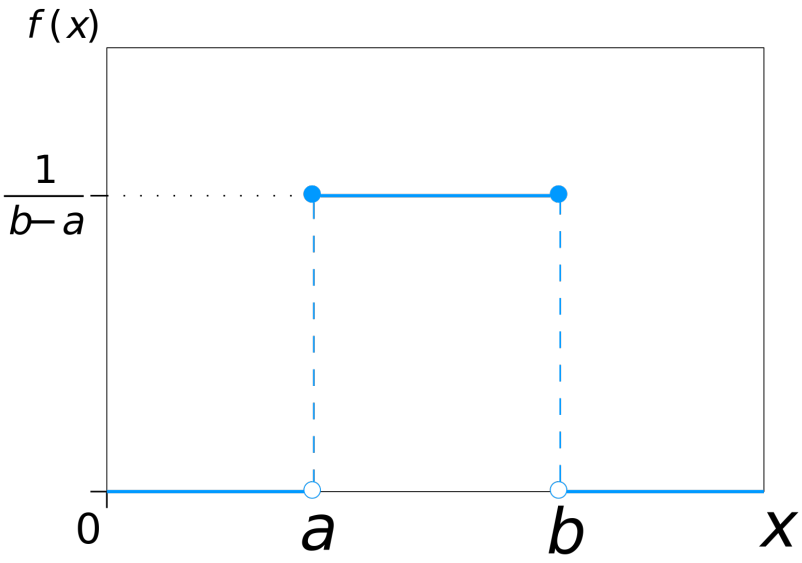

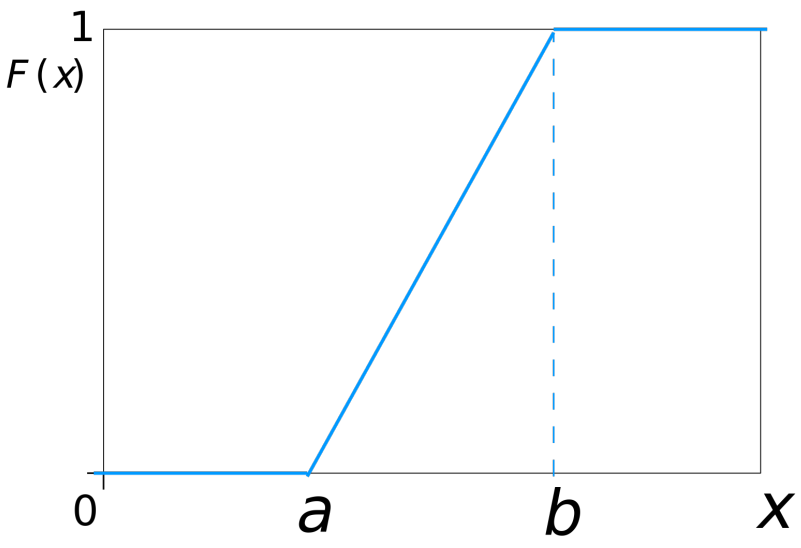

Loi exponentielle

Loi exponentielle $\mathcal{E}(\lambda)$ modélise la durée de vie d'un phénomène sans mémoire, ou sans usure, ou sans vieillissement. Elle modélise aussi le temps d'attente entre deux évènements qui suivent la loi de Poisson avec le paramètre λ. Sa densité de probabilité est donnée comme

$$f_X(x) = \lambda e^{-\lambda x}, \quad x \geq 0, \lambda > 0.$$

On peut montrer que :

- $F_X(x) = 1 - e^{-\lambda x}$, si $x \geq 0$ et 0 sinon.
- $\mathbb{E}[X] = \frac{1}{\lambda}$
- $Var[X] = \frac{1}{\lambda^2}$
- Mode : 0
- Médiane : $\frac{\ln 2}{\lambda}$

Exercice : montrer !

Loi exponentielle

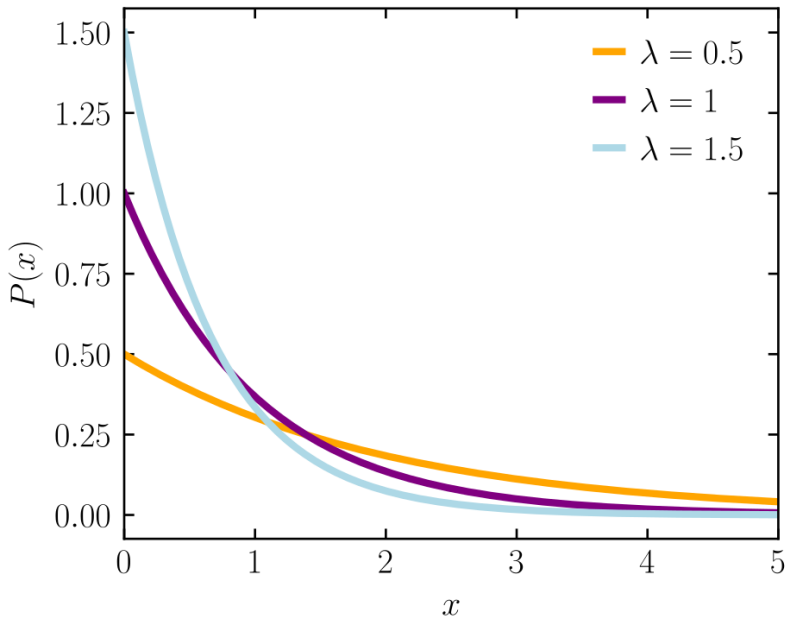

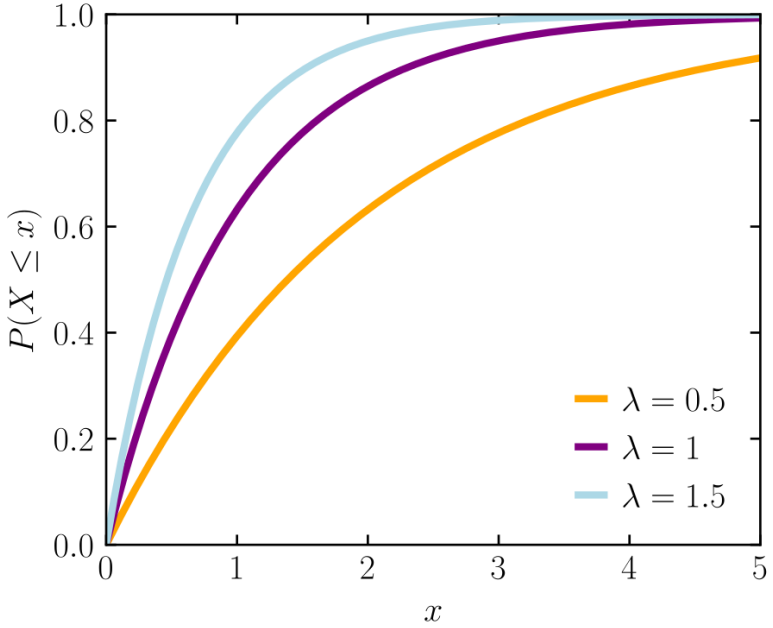

Loi normale (a.k.a. Gaussienne)

On note $X \sim \mathcal{N}(\mu, \sigma^2)$ si sa densité de probabilité est définie par

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(x-\mu)^2}, \quad x \in \mathbb{R}$$

L'espérance et la variance sont données par

- $\mathbb{E}[X] = \mu$
- $Var[X] = \sigma^2$
- Mode : μ
- Médiane : μ

Loi normale

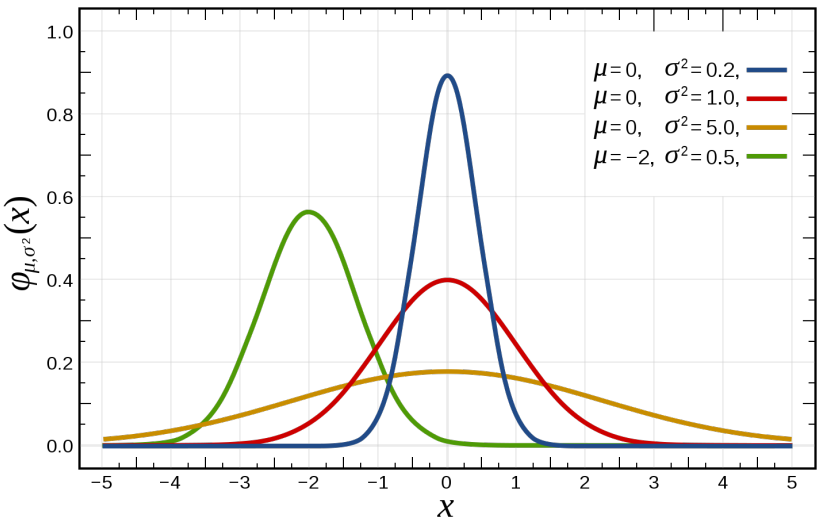
$\mu=0,\ \sigma^2=0.2,$
$\mu=0,\ \sigma^2=1.0,$
$\mu=0,\ \sigma^2=5.0,$
$\mu=-2,\ \sigma^2=0.5,$
$\varphi_{\mu,\sigma^2}(x)$
x

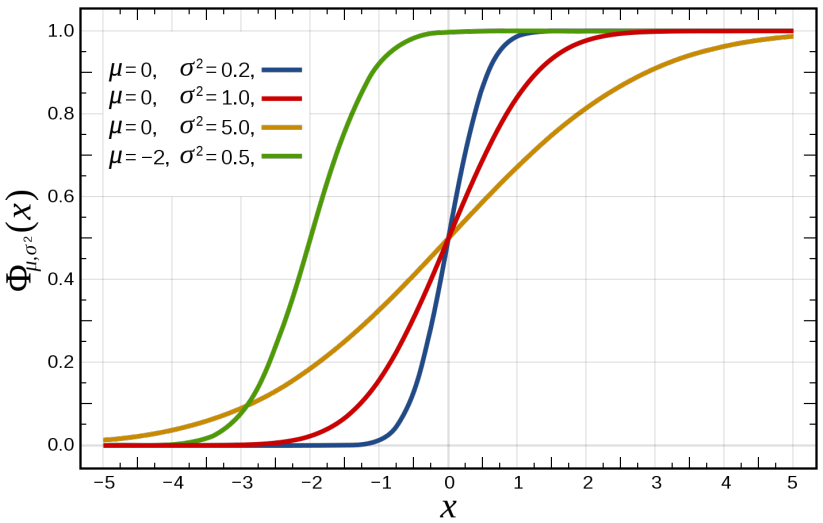
$\mu=0,\ \sigma^2=0.2,$
$\mu=0,\ \sigma^2=1.0,$
$\mu=0,\ \sigma^2=5.0,$
$\mu=-2,\ \sigma^2=0.5,$
$\Phi_{\mu,\sigma^2}(x)$
x

Comment simuler les variables continues dans R ?

- **Loi uniforme continue :** `runif(N,a,b)`
- **Loi exponentielle :** `rexp(N,lambda)`
- **Loi Normale :** `rnorm(N,mu, sigma)`,

où N – taille d'échantillon

Un peu plus sur la Loi Normale...

- C'est qu'on peut décrire avec la **loi normale** : la taille de la population, précision de conditionnement, etc
- Il y a des **lois** qui sont **'presque' normales** : par exemple, la loi Binomiale $\mathcal{B}(n, p)$ pour n très grand, la loi de Poisson pour λ très grand, Loi de Student, etc peuvent être approché par la loi Normale.
- Si nous avons beaucoup des observation de variables i.i.d. $\{X_i\}_{i=1,\dots,n}$, avec la moyenne μ et la variance σ^2, grâce à la **Théorème Centrale Limite** (plus tard dans le cours), on a

$$\frac{1}{\sqrt{n}}\left(\frac{1}{n}\sum_{i=1}^{n} X_i - \mu\right) \underset{n\to\infty}{\longrightarrow} \mathcal{N}(0, \sigma^2)$$

Du coup, comment définir la loi de probabilité ?

- Le plus souvent, on identifie la loi par la **fonction de répartition** !
- Pourquoi pas la densité : **lois discrètes n'ont pas la densité** !
- Pourquoi pas la fonction de masse : **lois continues n'ont pas de la fonction de masse** !
- Il existent même de lois qui en plus ne possèdent ni la densité, ni de la fonction de masse (example : Loi de Cantor) !
- Pourquoi pas l'espérance ou la variance, ou bien le mode ou la médiane :
  - Déjà, la distribution peut avoir **plusieurs modes ou médianes**
  - En plus, **l'espérance ou la variance** n'existent pas pour certaines lois !

Exemple 1 : Loi de Cantor

La loi de Cantor est définie comme une loi uniforme sur l'ensemble de Cantor. L'ensemble de Cantor, c'est l'intersection d'une infinité des intervalles suivantes :

$$
\begin{aligned}
C_0 =& [0,1] \\
C_1 =& [0,1/3] \cup [2/3,1] \\
C_2 =& [0,1/9] \cup [2/9,1/3] \cup [2/3,7/9] \cup [8/9,1] \\
C_3 =& [0,1/27] \cup [2/27,1/9] \cup [2/9,7/27] \cup [8/27,1/3] \cup \\
& [2/3,19/27] \cup [20/27,7/9] \cup [8/9,25/27] \cup [26/27,1] \\
C_4 =& \cdots .
\end{aligned}
$$

La loi de Cantor ne possède pas de la fonction de densité, ni de la fonction de masse ! (**Exercice : donner votre intuition pourquoi.**)

Exemple 1 : Loi de Cantor

... par contre, on peut définir la fonction de répartition (escalier de Cantor) :

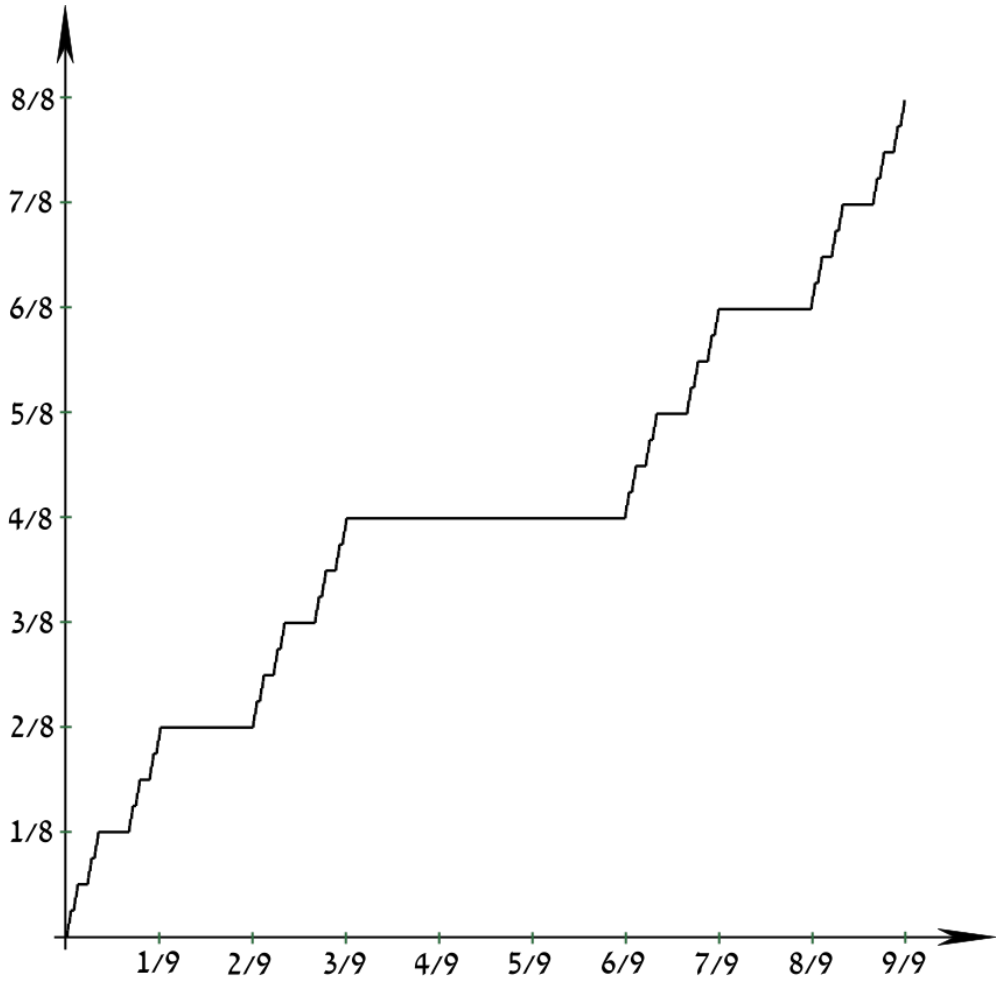

Exemple 2 : Loi de Cauchy

Considérons 2 variables indépendantes identiquement distribuées $X, Y \sim \mathcal{N}(0,1)$. Alors la variable $\frac{X}{Y} \sim Cauchy(0,1)$, avec la densité de probabilité donnée par

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad \forall x \in \mathbb{R}.$$

Pour la loi de Cauchy, l'espérance et la variance n'existent pas !

Exemple 2 : Loi de Cauchy

D'abord, on va vérifier que la fonction $f(x) = \frac{1}{\pi(1+x^2)}$ c'est bien une densité. Alors, on vérifie les propriétés suivantes :

1. $f(x) > 0$
2. $\int_{-\infty}^{\infty} f(x)\,dx = 1.$

Exemple 2 : Loi de Cauchy

D'abord, on va vérifier que la fonction $f(x) = \frac{1}{\pi(1+x^2)}$ c'est bien une densité. Alors, on vérifie les propriétés suivantes :

1. $f(x) > 0$
2. $\int_{-\infty}^{\infty} f(x)\,dx = 1.$

$$\int_{-\infty}^{\infty} \frac{dx}{\pi(1+x^2)} = \frac{1}{\pi}\,(\text{arctan } x)\Big|_{-\infty}^{\infty} = \frac{1}{\pi}\left(\frac{\pi}{2} - (-\frac{\pi}{2})\right) = 1$$

Exemple 2 : Loi de Cauchy

Alors, il s'agit bien d'une densité. Maintenant, on va essayer de calculer l'espérance :

$$\int_{-\infty}^{\infty} \frac{xdx}{\pi(1+x^2)} = \frac{1}{2\pi}\int_{-\infty}^{\infty} \frac{d(1+x^2)}{1+x^2} = \frac{1}{\pi}\ln(1+x^2)\Big|_{-\infty}^{\infty} = \infty - \infty$$

Alors, il n'y a pas d'espérance car l'intégral ne se converge pas !

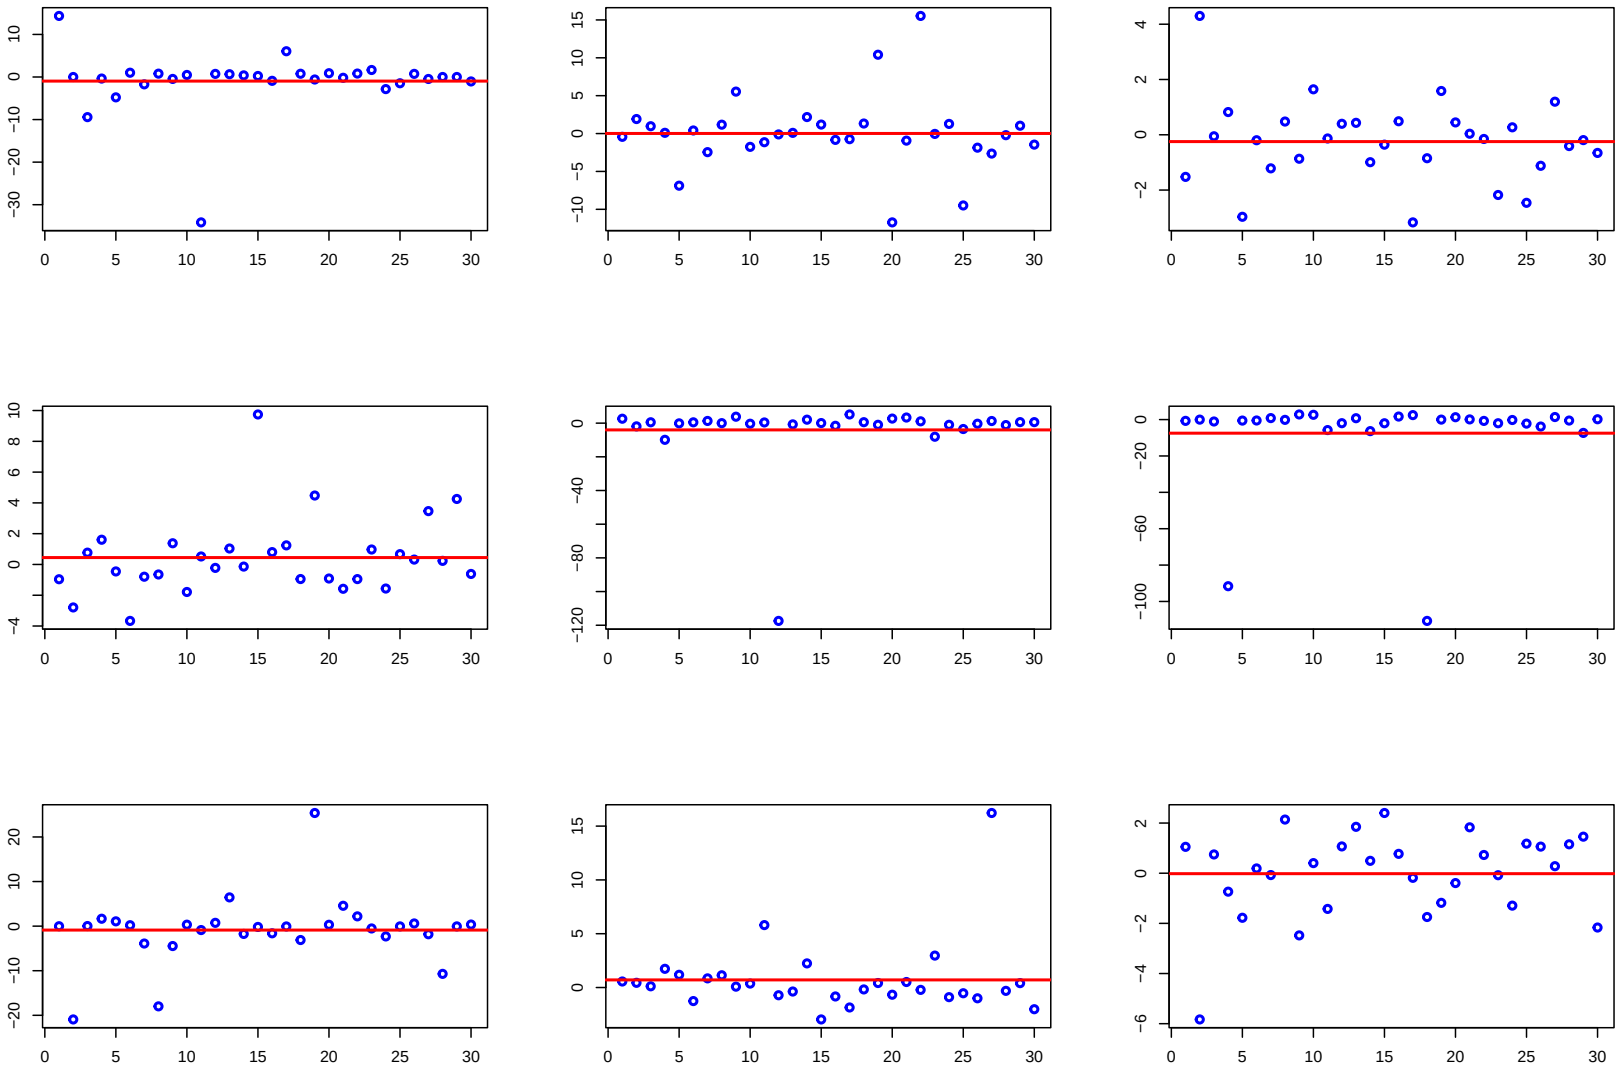

Lien entre la probabilité et statistiques

Probabilité = évènements futurs.	**Statistiques** = évènements passés.
Variable aléatoire	Observation
n épreuves aléatoires	Échantillon de taille n
Espérance $\mathbb{E}[X]$	Moyenne empirique $\bar{X}$
Probabilité d'un événement A	Fréquence d'apparition de A
Fonction de répartition F	F.d.r empirique $\hat{F}$
Mode, médiane	Mode, médiane empiriques

À quoi ça sert, faire de stat ?

- **Statistique** peut donner une représentation 'humaine' du monde réel, qui essaie de prendre en compte diverses variations aléatoires
- On utilise **l'inférence statistique** pour décrire les données récoltés (par les biologistes, chimistes, médecins), expliquer et prédire certains phénomènes
- L'inférence statistique est utilisée également pour trouver les **dépendances** entre différents événements

Définitions à retenir

- **Effectif :** nombre des observations dans chaque classe (groupe, type)
- **Fréquence :** proportion des observations dans chaque classe (groupe, type)
- **Effectif ou fréquence cumulées :** nombre/proportion des observations, inférieure à un classe (si pertinent)
- **Mode (empirique) :** classe à plus grand effectif
- **Médiane (empirique) :** valeur telle que 50% des observations sont en dessous

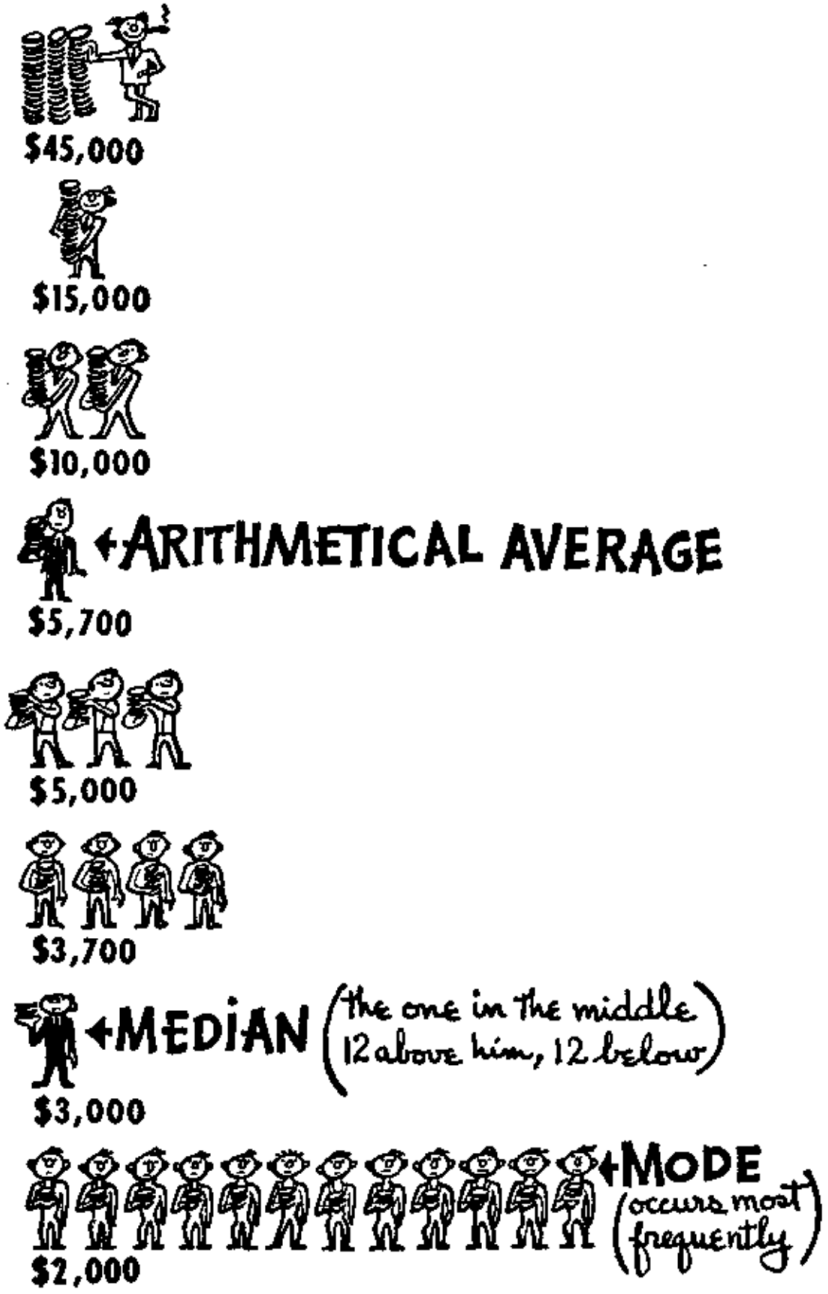
$45,000
$15,000
$10,000
ARITHMETICAL AVERAGE
$5,700
$5,000
$3,700
MEDIAN
(the one in the middle
12 above him, 12 below)
$3,000
MODE
(occurs most
frequently)
$2,000

Covariance et corrélation empiriques

- Pour voir s'il y a un lien entre 2 séries, on calcule **le coefficient de covariance empirique** :

$$\widehat{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y}),$$

où $\bar{x}$ et $\bar{x}$ sont les moyennes empiriques.

- Souvent, c'est plus pratique de travailler avec **le coefficient de la corrélation** :

$$\widehat{r}_{XY} = \frac{Cov(X, Y)}{\hat{\sigma}_X \hat{\sigma}_Y}$$

- Quand $\hat{r}_{XY} \approx 1$, ça veut dire que en moyenne, pour un changement positive dans X on a un changement positive dans Y. Quand $\hat{r}_{XY} \approx 0$, il n'y pas de dépendances particulières

Visualisation de la corrélation

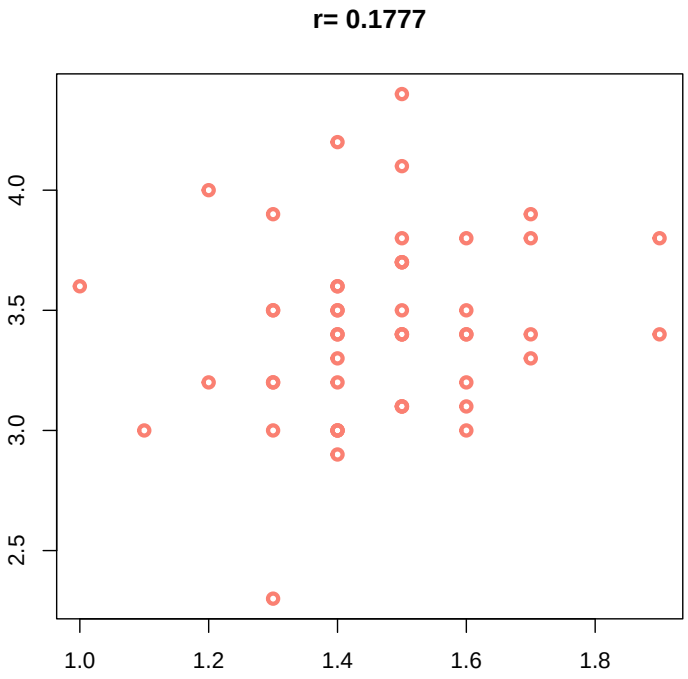

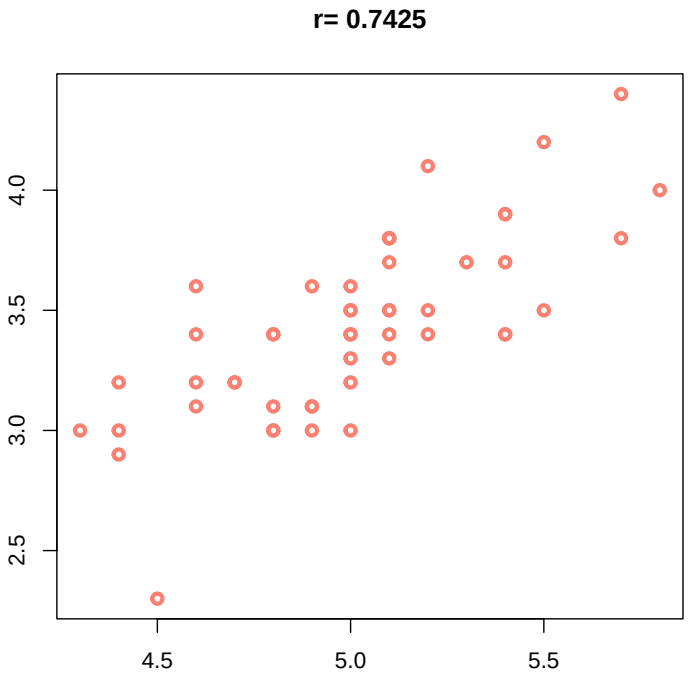

Corrélation $\neq$ dépendance !

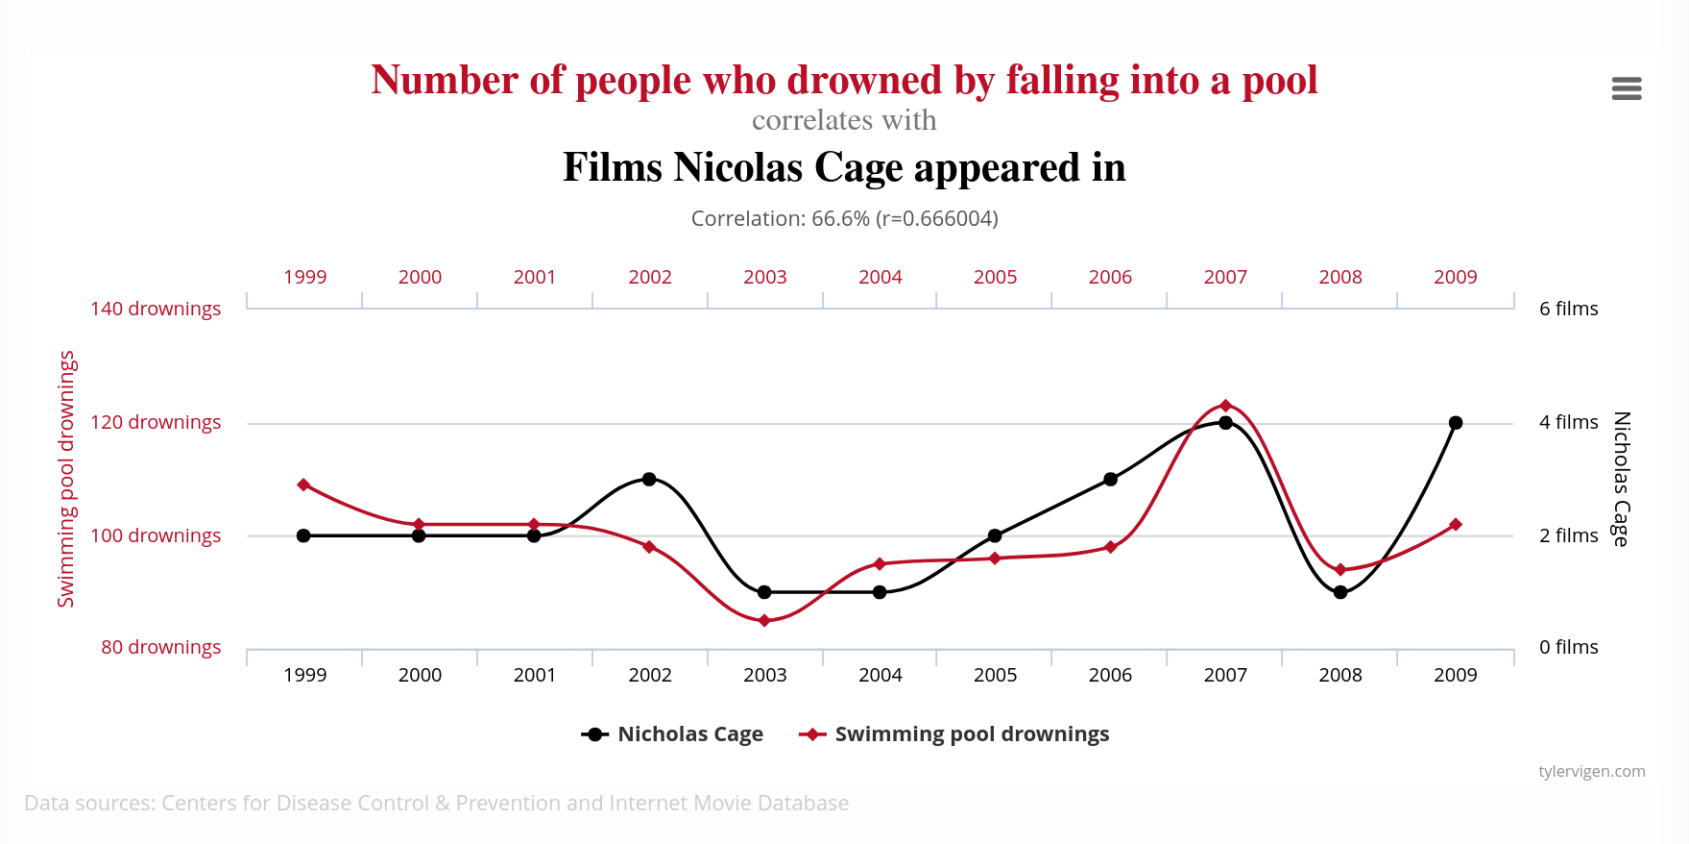

Corrélation $\neq$ dépendance !

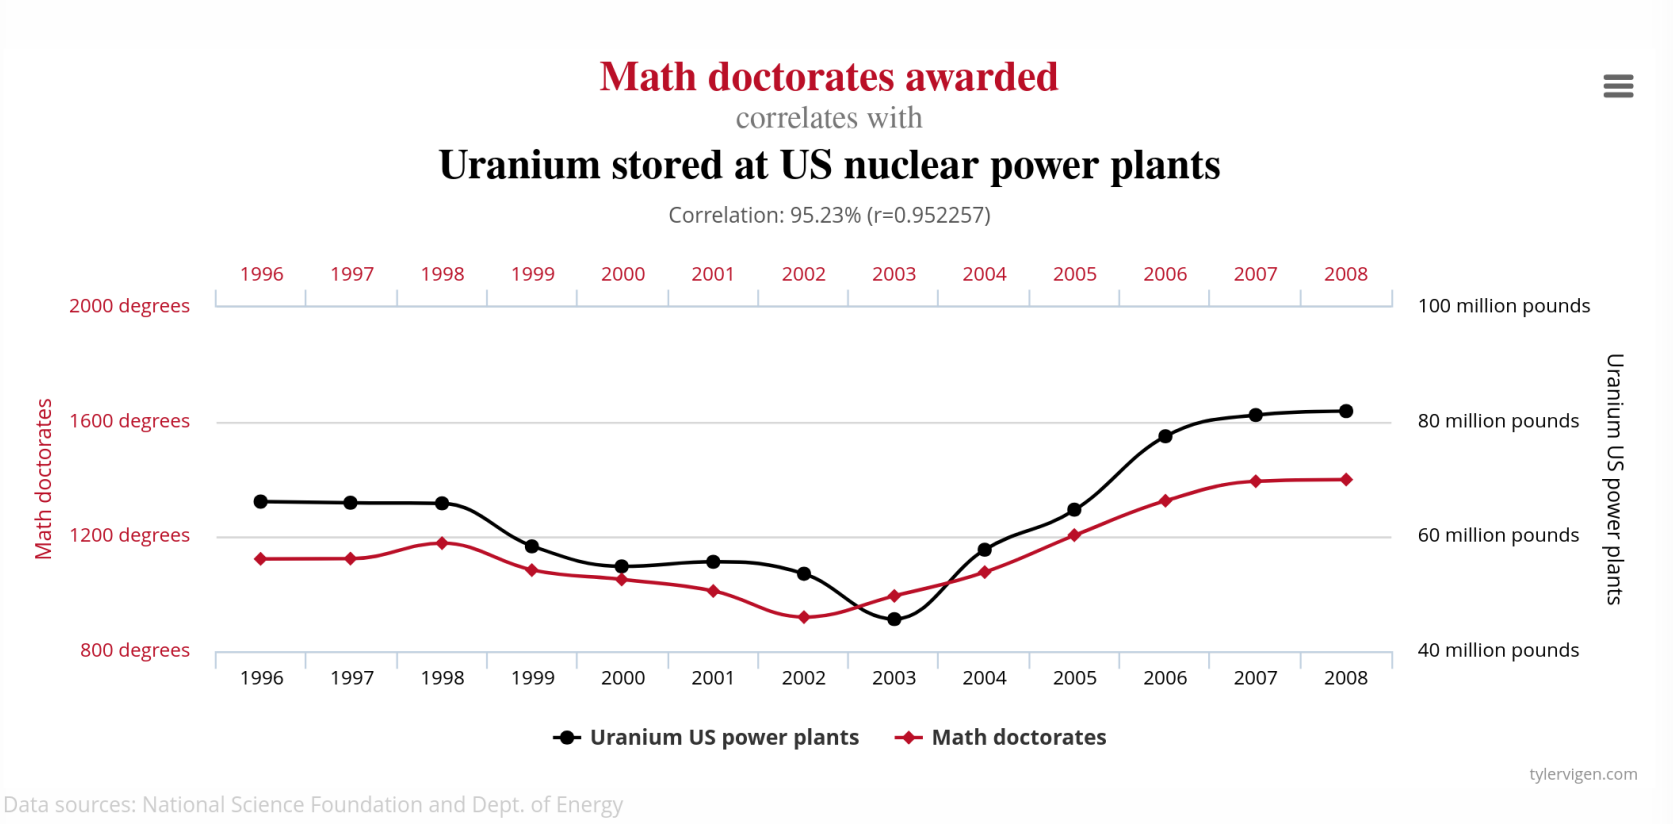

Data sources: National Science Foundation and Dept. of Energy

Conclusion

- Si le coefficient de corrélation (théorique) $r_{XY} \neq 0$, ça veut dire qu'il y a une dépendance entre X et Y
- Si le coefficient de corrélation (théorique) $r_{XY} = 0$, ça veut rien dire !
- Si le coefficient de corrélation (empirique) $\hat{r}_{XY} = 0$, dans la plupart de cas ça veut dire qu'il n'y a pas de dépendance entre les observations (au moins, il n'y a pas de tendance commune)
- Si le coefficient de corrélation (empirique) $\hat{r}_{XY} \neq 0$, ça veut dire que les séries changent ensemble. Ça ne prouve pas la dépendance théorique, ni que X est causé par Y, ni inverse !

Chapitre 3

Loi de grands nombres, théorème centrale limite.

AVIGNON UNIVERSITÉ

Inégalités

Théorème 3.1 (Inégalité de Markov)

Soit X une v.a. positive et d'espérance finie. Alors

$$\forall a \in \mathbb{R}^+ \quad \mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

Théorème 3.2 (Inégalité de Chebychev)

Soit X une v.a. d'espérance μ et de variance σ^2 finies. Alors,

$$\forall t \in \mathbb{R}^+ \quad \mathbb{P}(|X - \mu| \geq t) \leq \sigma^2 / t^2$$

Example

Soit X une v.a. uniforme sur $[0, 10]$. Comparer $\mathbb{P}(X \geq a)$ avec la majoration issue de l'inégalité de Markov, pour a égal à 2, 8 et 10.

Example

Soit $X \sim \mathcal{N}(0, 1)$. Comparer la valeur de $\mathbb{P}(|X| \geq 2)$ obtenue à l'aide de la table de la loi normale (on a $\mathbb{P}(X \geq 2) \approx 0.0227$) avec la majoration issue de l'inégalité de Chebychev.

Moyenne empirique

Si $X_1, \ldots, X_n$ sont indépendantes et identiquement distribuées (i.i.d) avec la moyenne μ et la variance σ^2, on défini la moyenne empirique comme :

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^{n} X_i$$

- calculer l'espérance et la variance de $\bar{X}_n$
- calculer $\mathbb{P}\left(|\bar{X} - \mu| > \varepsilon\right), \varepsilon > 0$

Loi des grands nombres

Théorème 3.3 (Loi faible des grands nombres)

Soit $X_1, X_2, \cdots$ une famille de variables aléatoires i.i.d. issue de X, d'espérance (μ) et de variance (σ^2) finies. On note $\bar{X}_n := (1/n)\sum_{i=1}^{n} X_i$ la moyenne arithmétique des n premières v.a. Alors,

$$\forall \epsilon > 0, \quad \mathbb{P}(|\bar{X}_n - \mu| \geq \epsilon) \underset{n\to\infty}{\longrightarrow} 0$$

Ce théorème est une application directe de l'inégalité de Chebychev. On dit que la moyenne arithmétique converge en probabilité vers l'espérance mathématique et on note $\bar{X}_n \overset{Prob}{\to} \mu$.

Loi des grands nombres

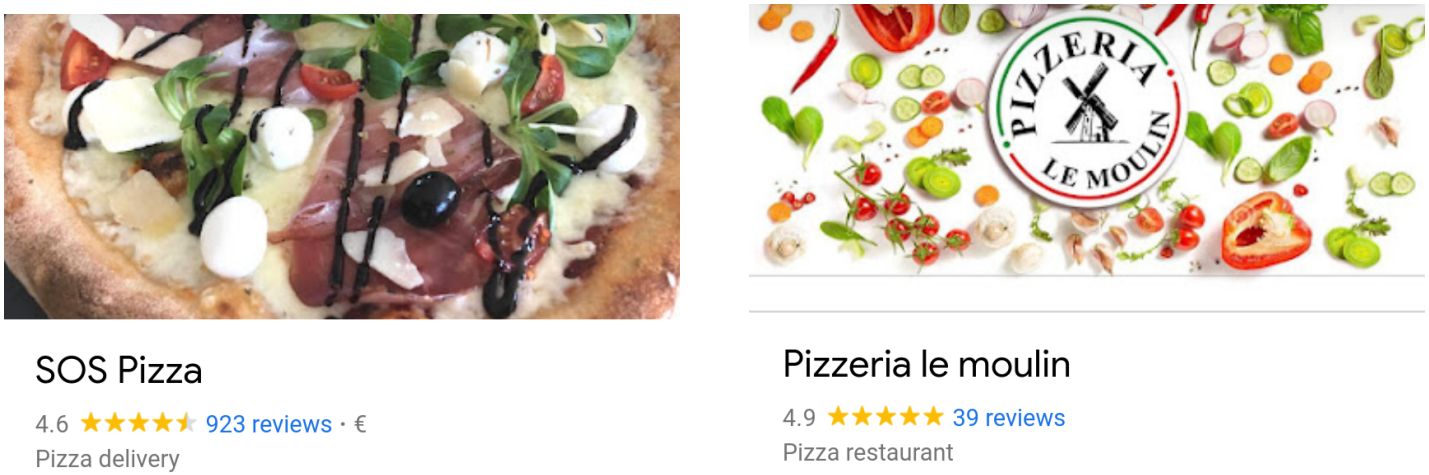

Figure 3 – Grâce à la loi des grands nombres, on comprend bien que la 'vraie' note pour "Pizza SOS" est plus proche à 4.6 que la 'vraie' note pour "Pizzeria le Moulin" – à 4.9...

Théorème Central Limite (TCL)

Soit $X_1, X_2, \cdots$ une famille de variables aléatoires i.i.d. issue de X, d'espérance μ et de variance σ^2 finies et $U \sim \mathcal{N}(0,1)$, indépendante des X_i. Alors,

$$\mathbb{P}\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq u\right) \underset{n\to\infty}{\longrightarrow} \mathbb{P}(U \leq u)$$

On dit que la loi de la moyenne arithmétique, centrée et réduite, converge vers une loi normale centrée réduite $\mathcal{N}(0,1)$ et on note

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

À quoi ça sert ?

- On utilise la loi de grandes nombres pour proposer les **estimateurs** de paramètres de la loi probabiliste (l'espérance, variance)
- Le théorème centrale limite nous permet en plus d'attribuer une certaine **confiance** aux estimateurs ponctuels.

Cas de la loi binomiale

Convergence de la loi binomiale vers la loi normale

On a déjà vu que si $X_1, \cdots, X_n$ sont n v.a. de Bernoulli $Ber(p)$ i.i.d. alors $Y := \sum_{i=1}^{n} X_i$ suit une loi $Bin(n,p)$. On a $\mathbb{E}[\bar{X}_n] = \mathbb{E}[Y/n] = p$ et $Var[\bar{X}_n] = Var[Y/n] = p(1-p)/n$, donc en appliquant le TCL à $\bar{X}_n = Y/n$, on obtient

$$\frac{Y/n - p}{\sqrt{p(1-p)/n}} = \frac{Y - np}{\sqrt{np(1-p)}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

On peut donc approcher la loi binomiale $Bin(n,p)$ par une loi normale $\mathcal{N}(np, np(1-p))$ quand n est grand. La loi Gaussienne est beaucoup plus pratique à manipuler que la loi binomiale, d'où l'intérêt de ce résultat. Dans la pratique, $np > 15$ et $nq > 15$ est considéré comme une condition sous laquelle cette approximation est jugée acceptable.

Étude d'un exemple : inégalité de Chebychev

- Considerons une suite de 60 variables $X_i \sim Ber(1/3), \quad i \in 1, \ldots, 60.$
- La somme $Y := \sum_{i=1}^{n} X_i$ suit une loi $Bin(60, 1/3)$.
- $\mathbb{E}[X_i] = \frac{1}{3}$, alors $\mathbb{E}[Y] = 20$. $Var[Y] = 60.1/3(1 - 1/3) = 40/3$
- L'inégalité de Chebychev donne :

$$\mathbb{P}(|Y - 20| \geq 7) \leq \frac{\sigma^2}{7^2} = \frac{40}{3.49} \simeq 0.27$$

Notons que la valeur exacte de $\mathbb{P}(|\mathbf{Y} - \mathbf{20}| \geq \mathbf{7}) \leq \frac{\sigma^2}{7^2} \simeq \mathbf{0.056}$ **!**

Étude d'un exemple : TCL

Estimons maintenant cette probabilité, en utilisant le TCL :

$$\frac{Y/n - p}{\sqrt{p(1-p)/n}} = \frac{Y - 20}{\sqrt{60.1/3.2/3}} = \frac{Y - 20}{\sqrt{120/9}} \approx \mathcal{N}(0,1).$$

On obtient alors

$$\mathbb{P}(|Y - 20| \geq 7) = \mathbb{P}\left(\frac{|Y - 20|}{\sqrt{120/9}} \geq \frac{7}{\sqrt{120/9}}\right)$$
$$\simeq \mathbb{P}(\mathcal{N}(0,1) \geq 1.92) \simeq 0.0552$$

Cette évaluation de l'erreur est beaucoup plus rassurante !

Exemples numérique : loi uniforme

```r
n = 1000
k = 1000
means <- numeric(n)

# CLT for uniform distribution
for (i in 1:n){
  u <- runif(k)
  means[i] <- mean(u)
}
means_norm <- sqrt(n)*(means-0.5)/sqrt(1/12)
```

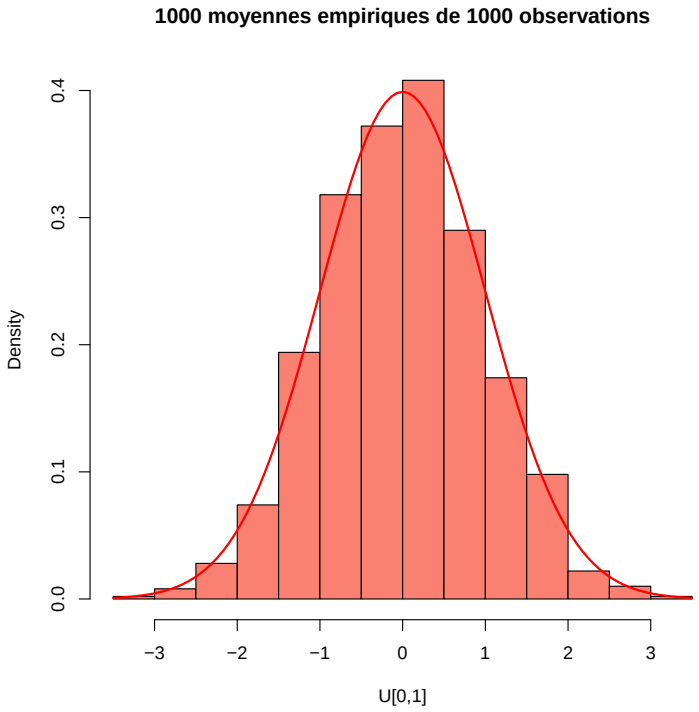

Exemples numérique : loi binomiale

```r
# CLT for binomial distribution
for (i in 1:n){
  bin <- rbinom(k, 100, 0.5)
  means[i] <- mean(bin)
}
means_norm <- sqrt(n)*(means-50)/5
```

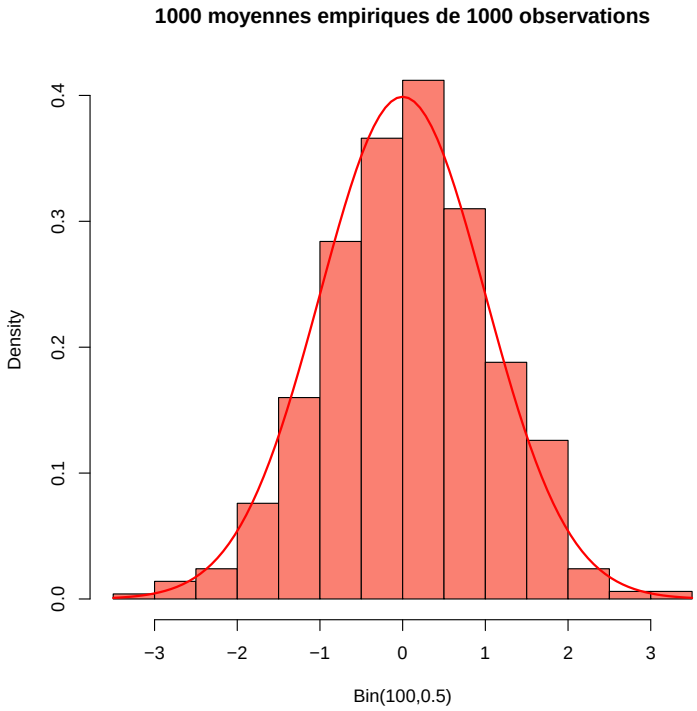

Exemples numérique : loi de Poisson

```r
# CLT for poisson distribution
for (i in 1:n){
  pois <- rpois(k, 1)
  means[i] <- mean(pois)
}
means_norm <- sqrt(n)*(means-1)
```

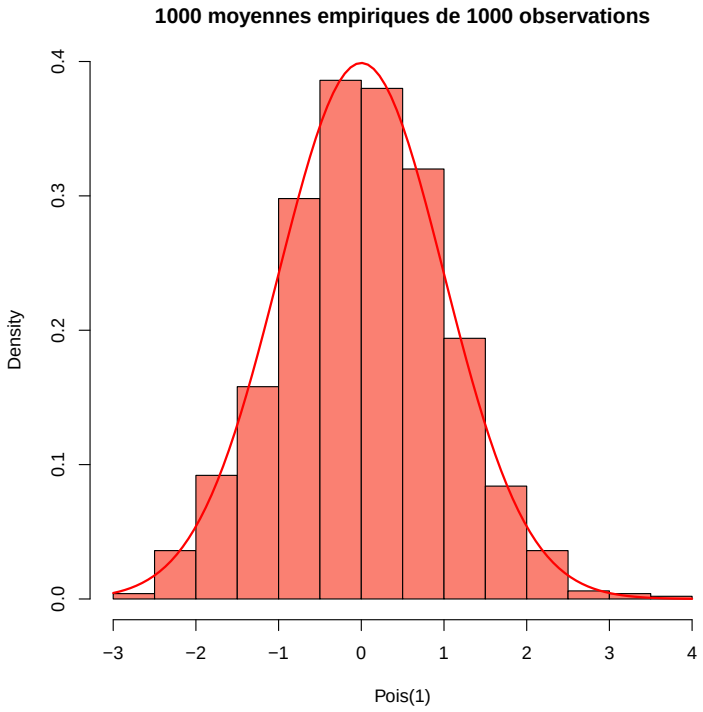

Exemples numérique : loi exponentielle

```r
# CLT for exponential distribution
for (i in 1:n){
  ex <- rexp(k, 1)
  means[i] <- mean(ex)
}
means_norm <- sqrt(n)*(means-1)
```

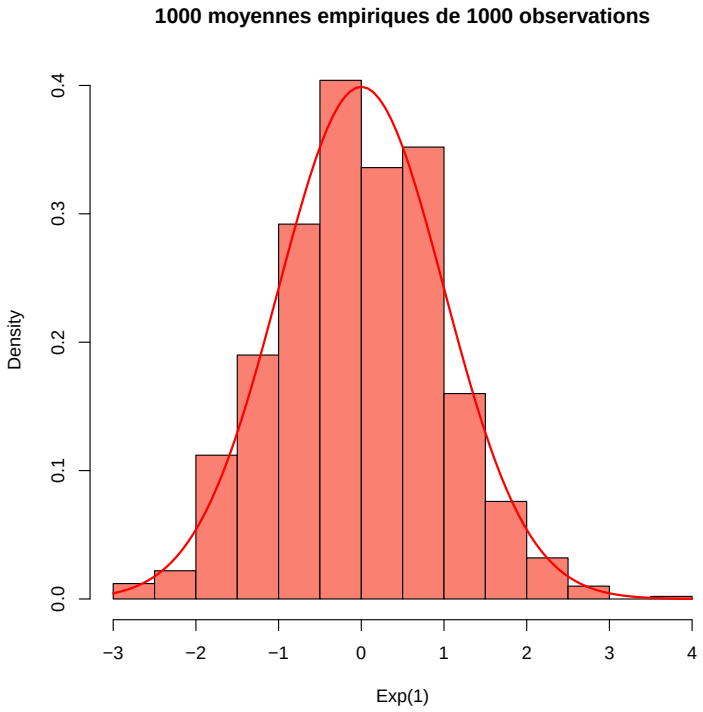

Exemples numérique : loi de Cauchy

```r
# CLT (non-working) for Cauchy distribution
for (i in 1:n){
  cauchy <- rnorm(k)/rnorm(k)
  means[i] <- mean(cauchy)
}
means_norm <- sqrt(n)*(means)
```

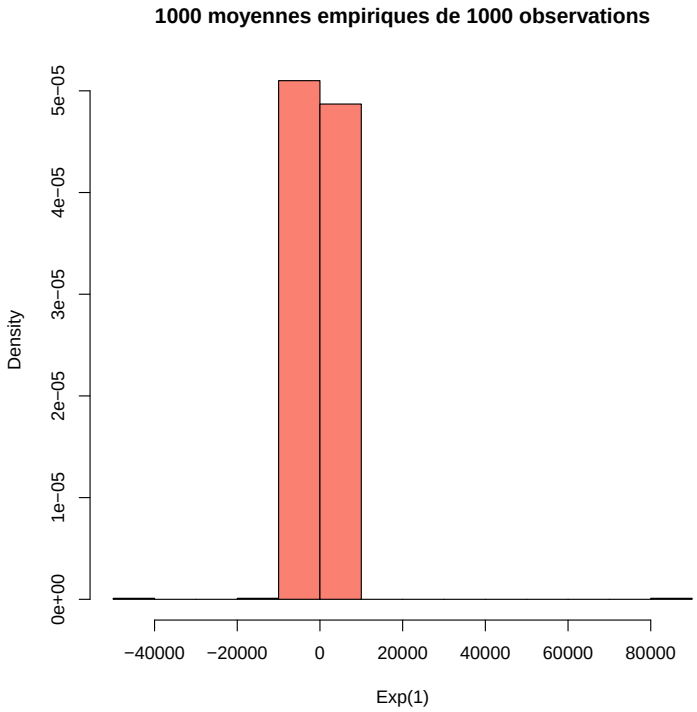

Chapitre 4

Statistique : Intervalles de confiance

AVIGNON UNIVERSITÉ

Un peu d'histoire : vaccine de polio

Année	Nombre de cas (États-Uni)
1952	60 000
1953	30 000
1954	?

La vaccine contre la polio de Jonas Salk a passé les épreuves cliniques en 1953. Comment évaluer son efficacité ?

Un peu d'histoire : vaccine de polio

Groupe	Taille	Taux d'incidence (sur 100 000)
Vaccin	200 000	28
Placebo (Contrôle)	200 000	71
Refus de vaccin	350 000	41

- Est-ce que la vaccination a **un effet** sur le taux d'incidence de polio ?
- Est-ce que **l'effet** de vaccination est **significatif**, ou il s'explique par une **coïncidence** ?
- Comment mesurer tout ça ?

Pourquoi l'estimation ponctuelle n'est pas suffisante ?

- L'estimateur est une variable aléatoire qui dépend de l'échantillon.
- Une simple estimation ponctuelle n'apporte aucune indication sur la *précision de l'estimation*.

Exemple : sondage

- les résultats d'enquêtes varient d'un institut de sondage à l'autre.
- Ce n'est pas la même chose de dire qu'un candidat est crédité de 53% d'intention de vote plus ou moins 10%, ou plus ou moins 2% !

Intervalles de confiance

Exemple : sondage

- **Estimation ponctuelle :** 53% ont intention de voter pour le candidat
- **Estimation par intervalle :** à risque de se tromper limité à 5%, le candidat aura entre 46 et 60 percent de votes.

Intervalles de confiance : intuition

- Pensez-vous qu'il soit possible qu'une estimation $\hat{p}_n$ soit égale au paramètre estimé ?
- Comment peut-on savoir l'ordre de grandeur d'écart entre l'estimation et le paramètre inconnu ?
- À votre avis, si on choisi l'intervalle de confiance de l'ordre 95%, est-ce qu'elle va être plus grande que l'IC l'ordre 50%

Théorème Central Limite (TCL)

Soit $X_1, X_2, \cdots$ une famille de variables aléatoires i.i.d. issue de X, d'espérance μ et de variance σ^2 finies et $U \sim \mathcal{N}(0,1)$, indépendante des X_i. Alors,

$$\mathbb{P}\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq u\right) \underset{n\to\infty}{\longrightarrow} \mathbb{P}(U \leq u)$$

On dit que la loi de la moyenne arithmétique, centrée et réduite, converge vers une loi normale centrée réduite $\mathcal{N}(0,1)$ et on note

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{\mathcal{L}} \mathcal{N}(0,1).$$

À quoi ça sert ?

- On utilise la loi de grandes nombres pour proposer les **estimateurs** de paramètres de la loi probabiliste (l'espérance, variance)
- Le théorème centrale limite nous permet en plus d'attribuer une certaine **confiance** ou **fiabilité** aux estimateurs ponctuels.

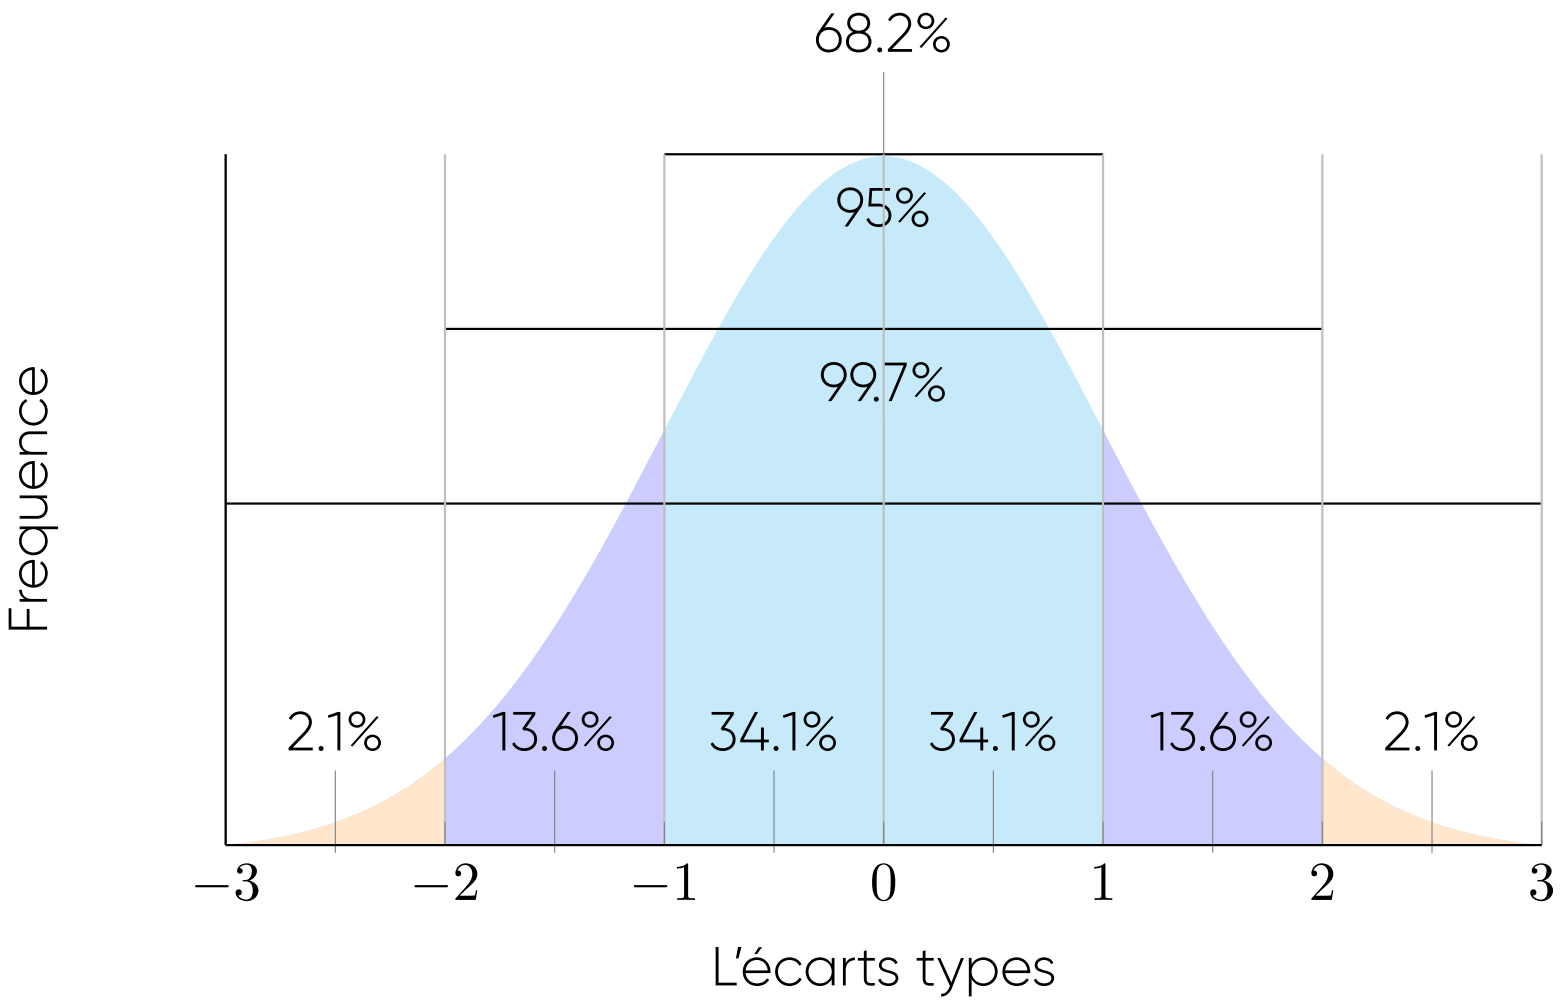
68.2%
95%
99.7%
2.1%
13.6%
34.1%
34.1%
13.6%
2.1%
−3
−2
−1
0
1
2
3
Frequence
L'écarts types

Intervalles de confiance : proportion

- On considère une population P, avec une proportion p d'individus de caractère 1, les autres étant de caractère 0.
- Cet échantillonnage est modelé par n variables aléatoires X_i de loi de Bernoulli $Ber(p)$.
- La variable aléatoire $\hat{P}_n$ "proportion relevée dans l'échantillon" approche le paramètre p.

Intervalles de confiance

Grâce à TCL on approche $\frac{\hat{P}_n - p}{\sqrt{\hat{P}_n(1-\hat{P}_n)/n}}$ par $\mathcal{N}(0,1)$.

Pour la loi normale $\mathcal{N}(0,1)$, on cherche le nombre $z_{1-\alpha/2}$ (appelé 'quantile de la loi normale d'ordre $1-\alpha/2$') pour lequel :

$$\mathbb{P}(-z_{1-\alpha/2} \leq \mathcal{N}(0,1) \leq z_{1-\alpha/2}) = 1-\alpha$$

Pour $\alpha = 0.05$, on a $z_{1-\alpha/2} = 1.96$.

Intervalles de confiance

Alors :

$$\begin{aligned} 1-\alpha &= \mathbb{P}(-z_{1-\alpha/2} \leq \mathcal{N}(0,1) \leq z_{1-\alpha/2}) \\ &\simeq \mathbb{P}\left(-z_{1-\alpha/2} \leq \frac{\hat{P}_n - p}{\sqrt{\hat{P}_n(1-\hat{P}_n)/n}} \leq z_{1-\alpha/2}\right) \end{aligned}$$

D'où on tire :

Intervalle de confiance

Avec probabilité $1-\alpha$,

$$p \in \left(\hat{p}_n - z_{1-\alpha/2}\sqrt{\hat{p}_n(1-\hat{p}_n)/n}, \hat{p}_n + z_{1-\alpha/2}\sqrt{\hat{p}_n(1-\hat{p}_n)/n}\right)$$

Quantiles de la loi normale

Si $X \sim \mathcal{N}(0,1)$, alors

- $\mathbb{P}(X > 2.33) = \mathbb{P}(X < -2.33) \approx 0.01$
- $\mathbb{P}(X > 1.96) = \mathbb{P}(X < -1.96) \approx 0.025$
- $\mathbb{P}(X > 1.64) = \mathbb{P}(X < -1.64) \approx 0.05$
- $\mathbb{P}(X > 1.28) = \mathbb{P}(X < -1.28) \approx 0.1$

Alternativement, on dit que $z_{0.01} = 2.33$, $z_{0.05} = 1.64$. Notons que $z_{1-\alpha} = -z_\alpha$. La valeur z_α est appelé **la quantile d'ordre** α.

Étude d'un exemple

On interroge $n = 895$ personnes et 502 répondent positivement.
Quel est l'intervalle de confiance au niveau $1 - \alpha = 95\%$?
L'application des formules donnent :

- $\hat{p}_n = 502/895 = 0.561$
- $p_1 = 0.561 - 1.96\sqrt{0.561 \cdot 0.439/895} = 0.528$
- $p_2 = 0.561 + 1.96\sqrt{0.561 \cdot 0.439/895} = 0.594$

Ainsi, la proportion de réponse positive dans la population totale est entre 0.528 et 0.594 avec une probabilité de 95%.

Remarque

En principe, pour utiliser l'approximation par la loi normale, il faut que :

- La **taille d'échantillon** soit supérieure à 30
- Le nombre d'individus avec **la réponse positive** $\hat{p}_n$ soit supérieure à 10
- Le nombre d'individus avec **la réponse négative** $1 - \hat{p}_n$ soit supérieure à 10

Exemple : vaccine de Salk

Groupe	Taille	Taux d'inc.	IC de 95%
Vaccin	200000	$28 \cdot 10^{-5}$	$[20 \cdot 10^{-5}, 35 \cdot 10^{-5}]$
Placebo (Contrôle)	200000	$71 \cdot 10^{-5}$	$[60 \cdot 10^{-5}, 82 \cdot 10^{-5}]$
Refus de vaccin	350000	$41 \cdot 10^{-5}$	$[32 \cdot 10^{-5}, 50 \cdot 10^{-5}]$

Maintenant, on voit qu'il y a une différence significative entre les groupes 'Vaccin' et 'Placebo'. Par contre, pour le groupe 'Refus de vaccin' c'est moins évident. Quoi faire ?

Comment interpréter les intervalles de confiance ?

Prenons l'intervalle de confiance pour une proportion de 95% percent.

- Quelle est la probabilité que la vraie proportion p se trouve dans cette intervalle ?
- Si on construit 1000 IC de 95% percent (sur les échantillons différents), combien des intervalles contiendront la vraie proportion p ?

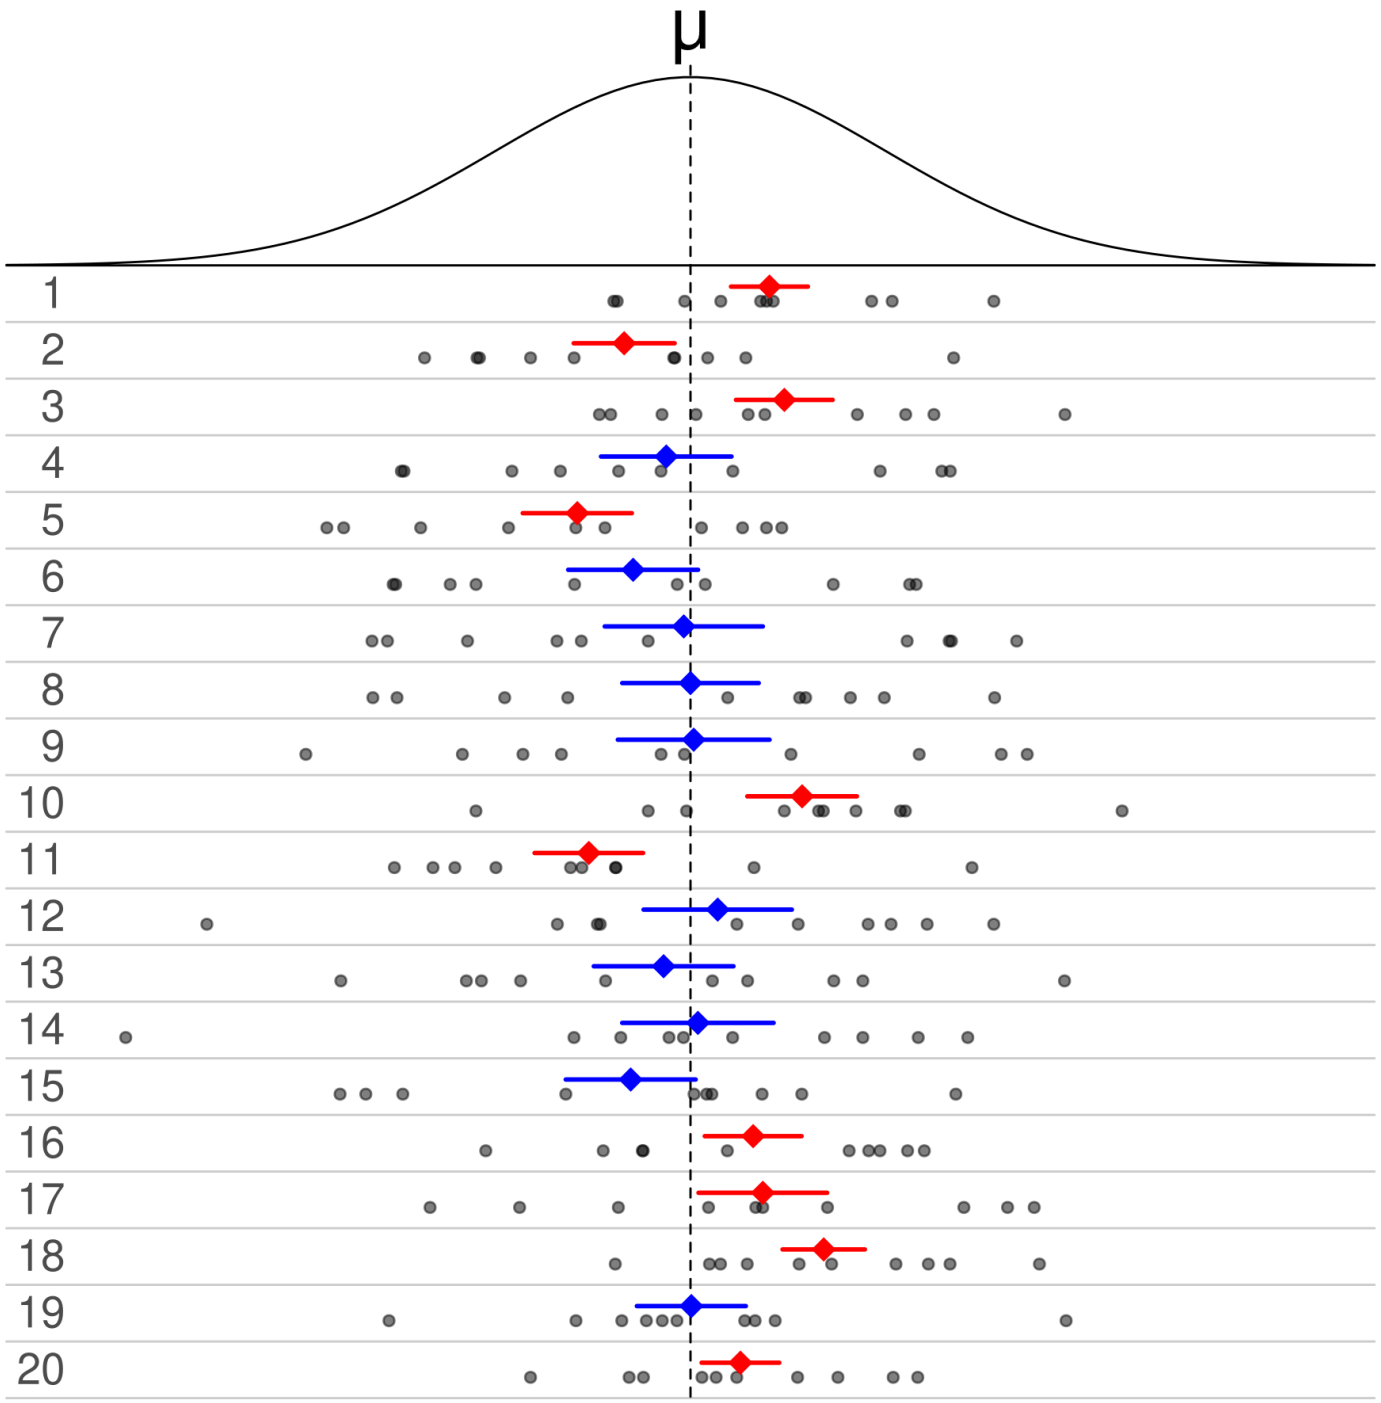
μ
1
2
3
4
5
6
7
8
9
10
11
12
13
14
15
16
17
18
19
20

Intervalles de confiance pour la moyenne

Considérons $X_1, \ldots, X_n \in \mathcal{N}(\mu, \sigma^2)$ i.i.d. On estime l'espérance et la variance empirique par :

$$\bar{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i \qquad \bar{S}^2 = \frac{1}{n-1}\sum_{i=1}^{n}\left(X_i - \bar{X}_n\right)^2$$

Alors, si la variance σ^2 est connue, on a :

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0,1).$$

Intervalles de confiance pour la moyenne

Si la variance n'est pas connue :

$$\frac{\bar{X}_n - \mu}{\bar{S}/\sqrt{n}} \sim St(n-1)$$

La distribution de Student ressemble à la distribution normale, mais elle a 'queues' lourdes.

Distribution de Student

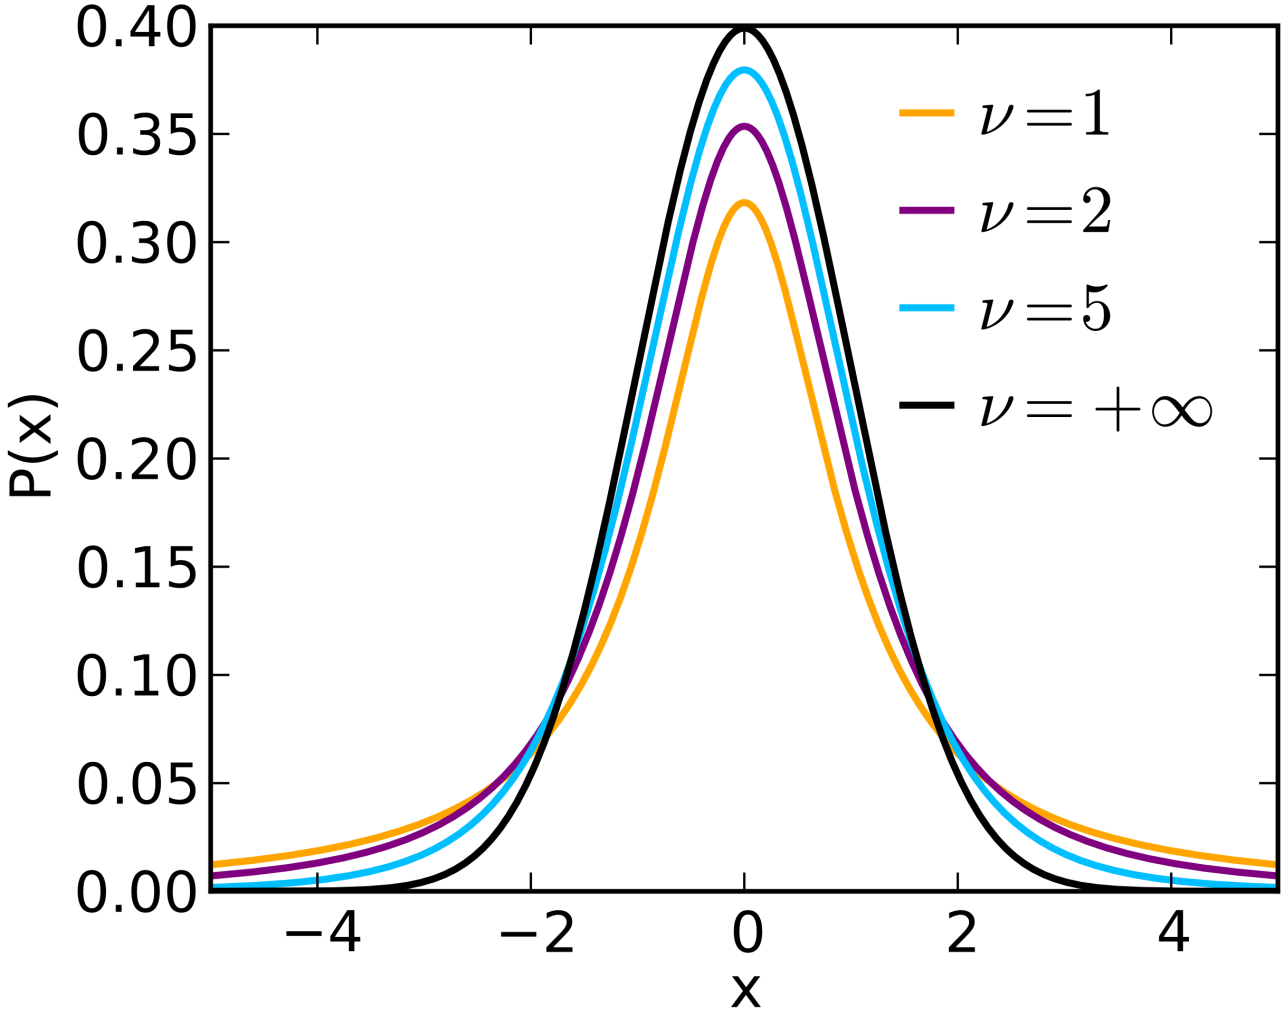

Quantiles de la loi normale

Si $X \sim St(10)$, alors

- $\mathbb{P}(X > 2.76) = \mathbb{P}(X < -2.76) \approx 0.01$
- $\mathbb{P}(X > 2.23) = \mathbb{P}(X < -2.23) \approx 0.025$
- $\mathbb{P}(X > 1.81) = \mathbb{P}(X < -1.81) \approx 0.05$
- $\mathbb{P}(X > 1.37) = \mathbb{P}(X < -1.37) \approx 0.1$

Exemple

Vous voulez louer un appartement de 30m2 à Avignon Intra-Muros. Le prix moyenne sur la première page de Leboncoin s'élève à 470, avec l'écart-type estimé de 50. Quelle est l'intervalle de confiance de 90% du prix d'appartement à l'Avignon Intra-Muros ?

Limites des intervalles de confiance ?

- Est-ce que notre paramètre est **bien en-dessous** (ou au-dessous) de certain seuil ?
- Est-ce qu'il y a une **différence significative** entre différents groupes ?
- Est-ce que notre **distribution est normale** ?
- Comment **quantifier les évidences** obtenues ?

Chapitre 5

Tests statistiques

AVIGNON UNIVERSITÉ

Limites des intervalles de confiance ?

- Est-ce que notre paramètre est **bien en-dessous** (ou au-dessous) de certain seuil ?
- Est-ce qu'il y a une **différence significative** entre différents groupes ?
- Est-ce que notre **distribution est normale** ?
- Comment **quantifier les évidences** obtenues ?

Exemple : vaccine de Salk

Groupe	Taille	Taux d'incidence (sur 100 000)
Vaccin	200 000	28
Placebo (Contrôle)	200 000	71
Refus de vaccin	350 000	41

Exemple : vaccine de Salk

- Prenons le taux moyen d'incidence de polio dans 3 groupes : $\frac{28+71+41}{3} \approx 47 \cdot 10^{-5}$
- On cherche à vérifier si dans le groupe 'Vaccin' le taux d'incidence est **significativement inférieur au taux moyen** (i.e. s'il ne s'agit pas d'une coïncidence)
- Notons $t_V = 28 \cdot 10^{-5}$ et la taille d'échantillon $n_V = 200000$.

Supposons que notre taux d'incidence est égale à $47 \cdot 10^{-5}$ et que la valeur observée c'est une coïncidence. C'est notre hypothèse zero :

$$H_0 : T_V = 47 \cdot 10^{-5}, \text{ (où } T_V \text{– le 'vrai' taux)}$$

Exemple : vaccine de Salk

Hypothèse de base

$$H_0 : T_V = 47 \cdot 10^{-5}, \text{ (où } T_V \text{– le 'vrai' taux)}$$

Si notre hypothèse H_0 est correcte, alors par le TCL on a :

$$\frac{\hat{T}_V - T_V}{\sqrt{\frac{T_V(1-T_V)}{n_V}}} \sim \mathcal{N}(0,1)$$

Exemple : vaccine de Salk

Hypothèse de base

$$H_0 : T_V = 47 \cdot 10^{-5}, \text{ (où } T_V \text{– le 'vrai' taux)}$$

Si notre hypothèse H_0 est correcte, alors par le TCL on a :

$$\frac{\hat{T}_V - T_V}{\sqrt{\frac{T_V(1-T_V)}{n_V}}} \sim \mathcal{N}(0,1)$$

La valeur de T_V qu'on observe dans l'exemple c'est $t_V = 28 \cdot 10^{-5}$. Alors, notre **statistique du test** est égale à :

$$\frac{28 \cdot 10^{-5} - 47 \cdot 10^{-5}}{\sqrt{\frac{47 \cdot 10^{-5}(1-47 \cdot 10^{-5})}{2 \cdot 10^5}}} = -\frac{19 \cdot 10^{-5}}{4.84 \cdot 10^{-5}} \approx -3.92$$

Exemple : vaccine de Salk

Hypothèse de base

$$H_0 : T_V = 47 \cdot 10^{-5}, \text{ (où } T_V \text{– le 'vrai' taux)}$$

- Assumer que notre hypothèse est vraisemblable est équivalent à assumer que l'observation -3.92 vient de la loi normale centrée réduite.
- Mais pour la loi normale, on a[1] :

$$\mathbb{P}\left(X \leq -3.92\right) \approx 1.9 \cdot 10^{-7}!$$

Alors, H_0 n'est pas très vraisemblable.

1. on peut calculer cette probabilité dans R : `pnorm(-3.92)`

Tests statistiques : Formalisation

- On prend **l'hypothèse zero** : $H_0 : p = p_0$.
- On décide quelle est **l'hypothèse alternative** : $H_0 : p > p_0$ ou $H_0 : p < p_0$ ou $H_0 : p \neq p_0$
- On décide quel est notre **niveau de risque** α (comme pour les intervalles de confiance).
- On utilise α pour calculer **le seuil critique** p_α
- On calcule **la statistique du test** :

$$\frac{\hat{p}_n - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

- Si la statistique du test dépasse p_α, on dit que **l'hypothèse** H_0 **est rejetée** avec le risque de se tromper α

Un autre exemple : Test d'un médicament

- Soit p **la probabilité de guérison** si on prend le nouveau médicament. Le taux de guérison par le placebo ou l'ancien médicament est considéré connu et est noté p_0.
- On test $\mathbf{H_0 : p = p_0}$ (le nouveau médicament n'apporte rien) contre $\mathbf{H_1 : p > p_0}$ (le nouveau médicament est mieux que les alternatives)
- On choisit **un niveau de risque** α (par exemple 5%, plutôt 1% si le nouveau médicament est connu pour avoir beaucoup d'effets secondaires).
- On va voir dans la suite comment on peut calculer une **valeur critique** p_α théorique. Si la proportion de malades guéris dans le groupe d'étude avec le nouveau médicament est $> p_\alpha$, alors on peut conclure avec une niveau de probabilité α que l'hypothèse H_0 peut être rejetée.

Calcul de la valeur critique

- On travaille sous l'hypothèse $p = p_0$.
- On considère la nouveau que la variable aléatoire "guérison de malade utilisant le nouveau médicament" est une loi de Bernoulli $Ber(p_0)$, et donc, en utilisant le TCL

$$\frac{\hat{p}_n - p_0}{\sqrt{p_0(1-p_0)/n}} \sim \mathcal{N}(0,1).$$

- Quelle est alors la probabilité de d'avoir $\hat{p}_n > p_\alpha$? Cette probabilité est égale à :

$$\mathbb{P}\left(\frac{\hat{p}_n - p_0}{\sqrt{p_0(1-p_0)/n}} > \frac{p_\alpha - p_0}{\sqrt{p_0(1-p_0)/n}}\right)$$

et peut être approché par :

$$\mathbb{P}\left(\mathcal{N}(0,1) > \frac{p_\alpha - p_0}{\sqrt{p_0(1-p_0)/n}}\right)$$

Calcul de la valeur critique

On cherche la valeur critique p_α telle que
$\mathbb{P}\left(\mathcal{N}(0,1) > \frac{p_\alpha - p_0}{\sqrt{p_0(1-p_0)/n}}\right) = \alpha$, donc celle pour laquelle

$$\frac{p_\alpha - p_0}{\sqrt{p_0(1-p_0)/n}} = z_{1-\alpha}$$

où $z_{1-\alpha}$ est la quantile d'ordre $1-\alpha$.
Donc :

Valeur critique

$$p_\alpha = p_0 + z_{1-\alpha}\sqrt{p_0(1-p_0)/n}$$

Exemple pratique

- On considère une maladie grave dont **le taux de guérison** est 35%. On teste un nouveau médicament sur 84 malades, dont 38 survivent. La proportion de survivants est donc :

$$\hat{p} = 38/84 = 0.4524$$

- **La valeur critique** est pour une certitude $\alpha = 5\%$ est

$$p_c = 0.35 + 1.64\sqrt{0.35 \times 0.65/84} = 0.4355$$

- Comme $\hat{p}_n$ est bien au-dessus de cette valeur critique, on peut estimer que la probabilité que H_0 soit vraie est en dessous de 0.05, et on écarte donc cette hypothèse.

Remarque : Si on choisit $\alpha = 0.01$, alors $z_{1-\alpha} = 2.33$ et on obtient $p_c = 0.471$. Dans ce cas, on ne rejettera pas H_0.

Exemple dans R

```
> x<- c(rep(1,38), rep(0,84-38))
> prop.test(sum(x),length(x),p = 0.35,alternative="greater")

»   1-sample proportions test with continuity correction

data:  sum(x) out of length(x), null probability 0.35
X-squared = 3.4333, df = 1, p-value = 0.03195
alternative hypothesis: true p is greater than 0.35
95 percent confidence interval:
 0.3602697 1.0000000
sample estimates:
       p
0.452381
```

Exemple dans R : explication

- **Sample estimate :** estimation ponctuelle, $\hat{p}_n = 0.45$.
- **p-value :** 0.03195. Sens mathématique : si $p_0 = 0.35$, alors

$$\mathbb{P}\left(\hat{p}_n \geq 0.4524\right) = 0.03195$$

  On doit rejeter H_0 si la p-valeur est plus grande que α. Ici, on rejette si $\alpha = 0.05$, mais on ne rejette pas si $\alpha = 0.01$!
- **95% confidence interval** : Car $\hat{p}_n = 0.45$, alors

$$\mathbb{P}\left(p \geq 0.36027\right) = 0.95$$

Comment choisir α ?

- Quand on rejette une hypothèse, on dit que la probabilité qu'elle soit vraie est inférieure à α (**elle peut être toujours vraie !**)
- Du coup, il y a **au plus** $\alpha\%$ de chances qu'on rejette l'hypothèse pour rien !
- Le choix du risque α dépends de la **gravité de conséquences** en cas du rejet.
- D'autre côté, quand α est trop petit, **on risque de ne jamais tirer de conclusions** utiles à partir des données.

Exemple : loi de Poisson

Vous avez la responsabilité de la gestion d'un **serveur informatique**.

- Ce serveur reçoit des requêtes, en nombre aléatoire.
- Vous faites une analyse statistique afin de dimensionner la puissance de votre serveur.
- Le nombre de requêtes par minute est modélisé à l'aide d'une loi de Poisson de paramètre inconnu λ.

Exemple : loi de Poisson

1. Proposer l'estimateur ponctuel $\hat{\lambda}$ de λ
2. Si on a observé 144 requêtes durant une heure, combien vaut $\hat{\lambda}$?
3. Donner l'estimation par intervalle de $\hat{\lambda}$ au niveau de confiance de 95%.
4. Votre manager avait comme hypothèse qu'il y aurait en moyenne 2 requêtes par minute. Tester cette hypothèse au niveau 5%.
5. Calculer la p-valeur associée aux hypothèses de ce test.

Exemple : loi de Poisson

1. $\hat{\lambda}$ – nombre moyen de requêtes observées par minute
2. $\hat{\lambda} = \frac{144}{60} = 2.4$
3. Avec proba 0.95, on a

$$\lambda \in \left[2.4 - 1.96 \cdot \sqrt{2.4/60}, 2.4 + 1.96 \cdot \sqrt{2.4/60}\right] \approx [2.008, 2.792]$$

4. Si $\lambda = 2$, alors

$$\frac{\hat{\lambda} - 2}{\sqrt{2 \cdot 60}} \sim \mathcal{N}(0, 1).$$

On observe $\hat{\lambda} = 2.4$. Or

$$\mathbb{P}\left(X \geq \frac{2.4 - 2}{\sqrt{2 \cdot 60}}\right) = \mathbb{P}\left(X \geq 2\right) = 0.0228 < \frac{0.05}{2}$$

Alors, **on rejette H_0 en prenant le risque de se tromper 5%** !

Tests de moyenne

- Le test précédent était de type **test de proportion** (on essaie de déterminer une proportion de survivants). On peut être amené à tester une valeur moyenne, c'est alors un **test de moyenne.**
- Cette fois-ci, les variables aléatoires $X_1, \dots, X_n$ ne sont pas à valeurs 0 ou 1, mais sont des **variables aléatoires continues** i.i.d. On suppose ici que leur variance σ^2 est connue, et on cherche à déterminer leur espérance μ (leur moyenne).
- Ici, nos hypothèses sont :

$$H_0 : \mu = \mu_0$$
$$H_0 : \mu \neq \mu_0$$

où μ_0 est une quantité connue.

Valeur critique

- On travaille sous l'hypothèse $H_0 : \mu = \mu_0$.
- D'après le TCL,
$$\frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} \simeq \mathcal{N}(0,1).$$
- On fixe un risque α, et on considère le nombre $z_{\alpha/2}$ pour lequel $\mathbb{P}(-z_{\alpha/2} \leq \mathcal{N}(0,1) \leq z_{\alpha/2}) = 1 - \alpha$.
- Alors, avec le même calcul que pour les intervalles de confiance, on introduit $\mu_1 = \mu_0 - z_{\alpha/2}\sigma/\sqrt{n}$ et $\mu_2 = \mu_0 + z_{\alpha/2}\sigma/\sqrt{n}$, de sorte que :

$$\begin{aligned}
\mathbb{P}(\mu_1 < \bar{X}_n < \mu_2) &= \mathbb{P}\left(-z_{\alpha/2} < \frac{\bar{X}_n - \mu_0}{\sigma/\sqrt{n}} < z_{\alpha/2}\right) \\
&\simeq \mathbb{P}\left(-z_{\alpha/2} \leq \mathcal{N}(0,1) \leq z_{\alpha/2}\right) \\
&= 1 - \alpha
\end{aligned}$$

Valeur critique

Ainsi, sous l'hypothèse H_0, la probabilité que la moyenne observée $\bar{X}_n$ soit hors de l'intervalle $[\mu_1, \mu_2]$ est inférieure à α. Si celà se produit, on doit rejeter l'hypothèse H_0.

Exemple pratique

- On suppose que le quotient intellectuel (QI) suit la loi normale $\mathcal{N}(100, 20^2)$.
- On fait passer le test à 36 étudiants. On observe une moyenne de QI de 106.1.
- Au risque $\alpha = 0.05$, peut-on conclure que les étudiants ont un QI moyen différent du reste de la population ?

Exemple pratique

On teste :

$$H_0 : \mu = 100$$
$$H_1 : \mu \neq 100$$

Calculons les valeurs critiques. On a ici $\sigma = 20$, $n = 36$ et $\bar{X}_n = 106.1$:

$$\mu_1 = \mu_0 - z_{\alpha/2}\frac{\sigma}{\sqrt{n}} = 100 - 1.96 \cdot 20/6 = 93.5$$
$$\mu_2 = 100 + 1.96.20/6 = 106.5$$

Alors, on rejette H_0 si $\bar{X}_n \notin [\mu_1, \mu_2]$. Or, on a $106.1 \in [\mu_1, \mu_2]$. On peut plutôt dire donc que les étudiants sont dans la moyenne.